DiffusionFF: A Diffusion-based Framework for Joint Face Forgery Detection and Fine-Grained Artifact Localization

CVPR 2026

背景

1、人脸伪造检测可以定义如下:

给定一张人脸图像，模型判断它是真实图像还是被篡改过的伪造图像，并输出一个 0～1 之间的伪造分数，分数越接近 1，越可能是伪造的。

2、伪影定位（DSSIM 图）的定义如下:

将伪造图像与其对应的真实图像逐像素对齐，在每个像素位置用局部窗口计算结构不相似度 DSSIM（= 1 − SSIM），得到一张灰度图：越亮表示该位置篡改越明显，真实图像的 DSSIM 图为全黑。

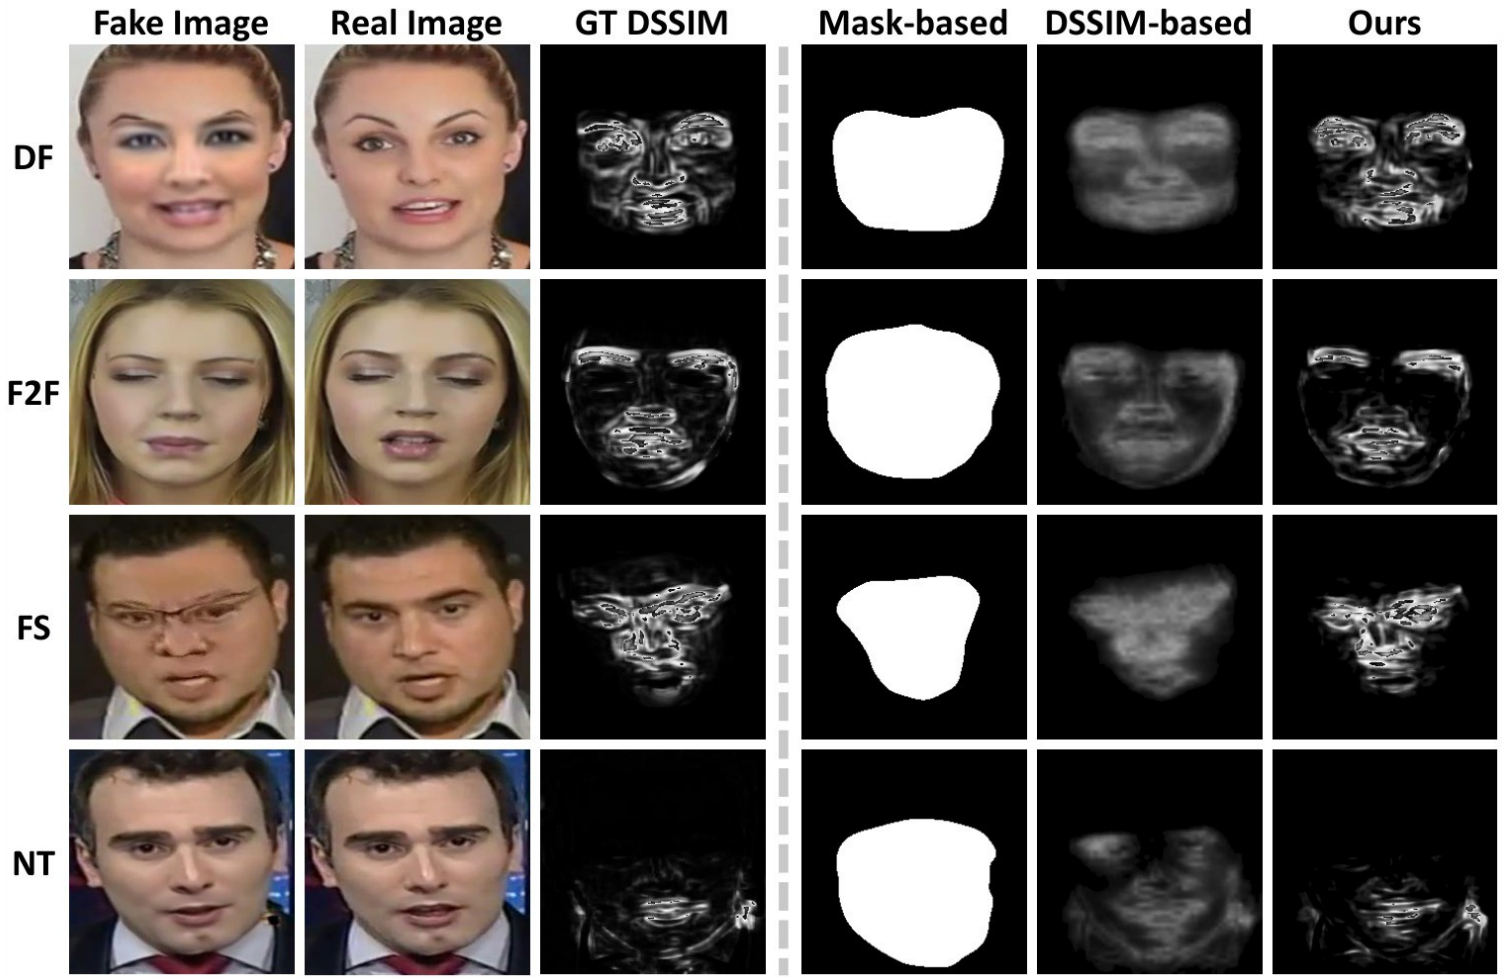
3、论文需要解决的问题为：只给一张待检测人脸，模型应该如何同时完成伪造检测和细粒度伪影定位，并利用定位结果提升检测性能。

FF++ 中的四种伪造方法:
DeepFakes (DF)： 深度学习换脸
Face2Face (F2F)： 表情迁移
FaceSwap (FS)： 图形学换脸
NeuralTextures (NT)： 神经渲染改表情

Input Image → (Forgery Score, DSSIM Map)

动机 1

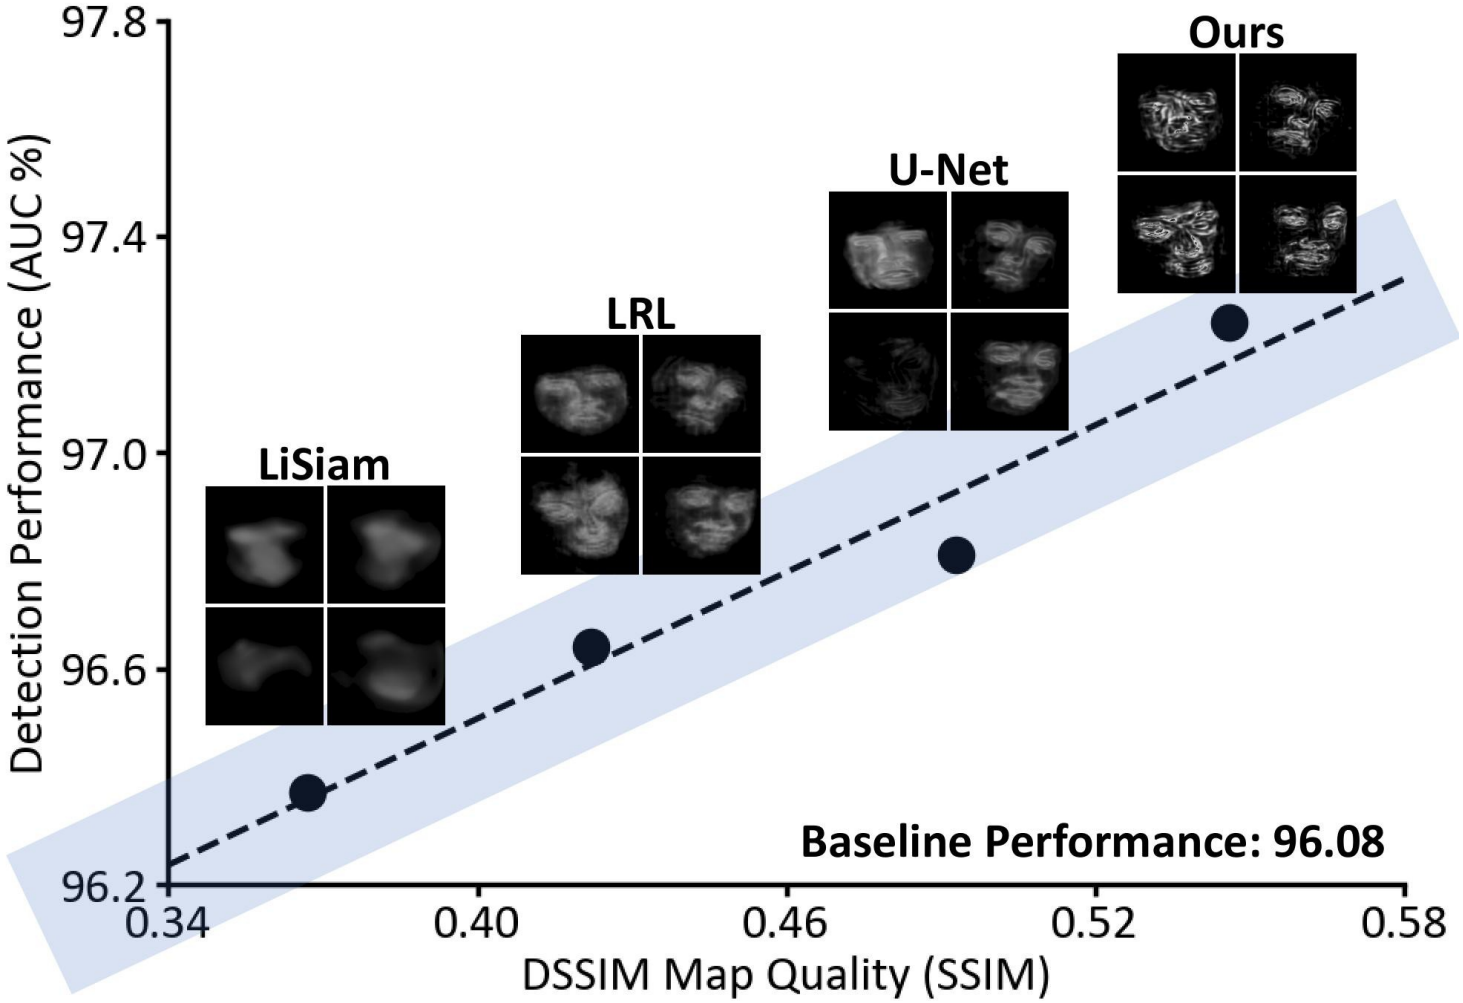
· 现有定位方法中，基于 Mask 的结果过于**粗糙**，基于 DSSIM 的直接回归结果**模糊**。



创新点 1

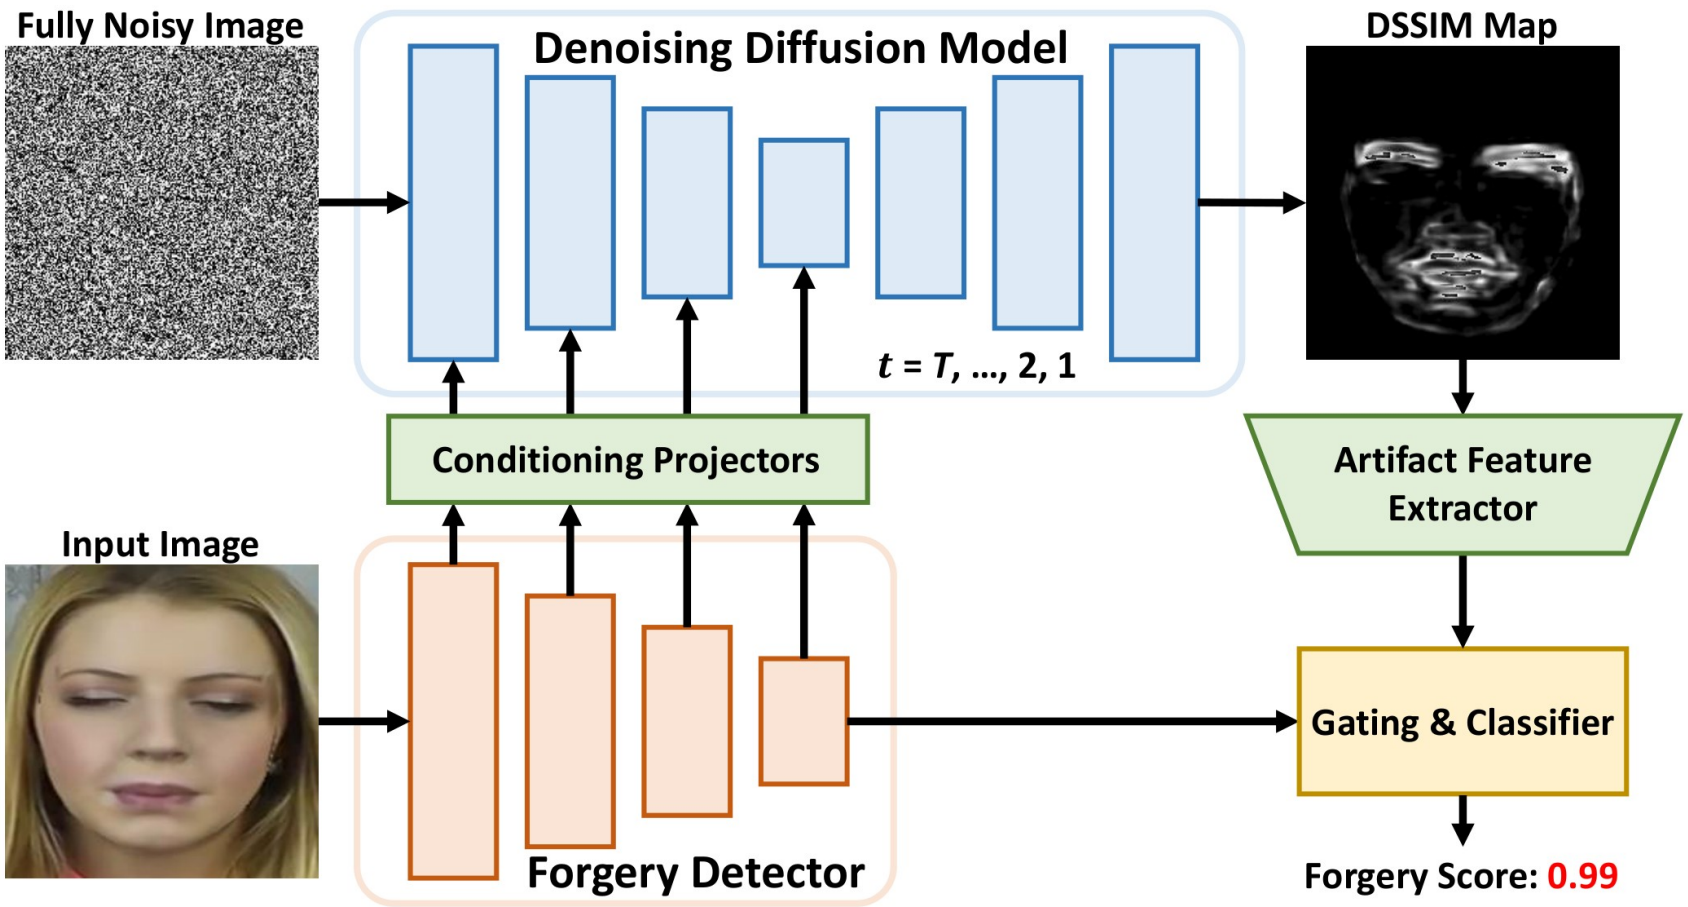
· 以预训练伪造检测器为“伪影编码器”、扩散模型为“伪影解码器”，逐步生成精细的 DSSIM 图。

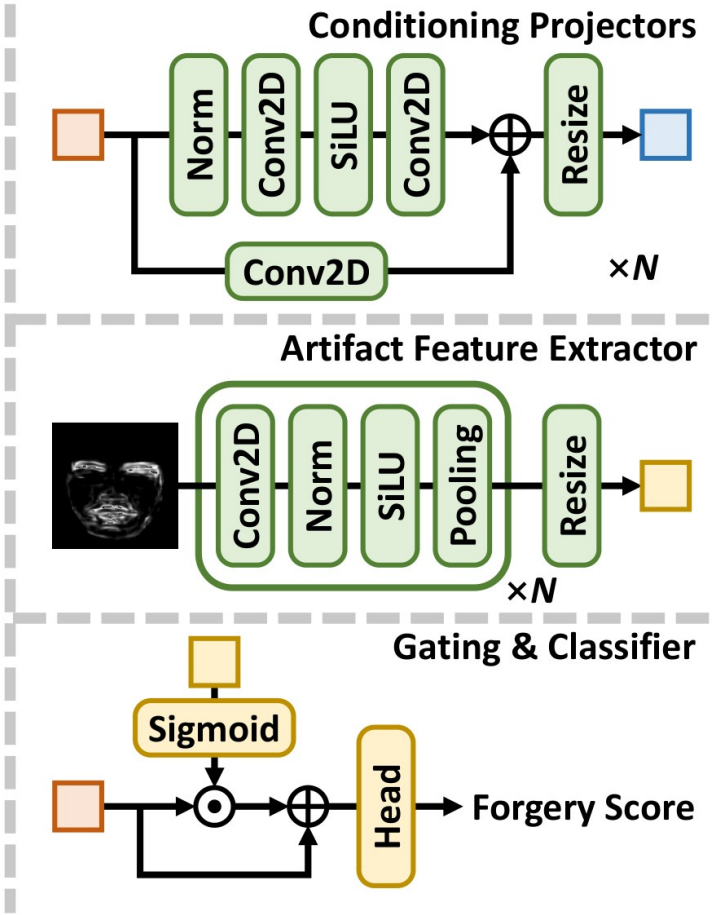
动机 2 · 估计的 DSSIM 图**质量越高**，融合后的检测性能提升越大。



创新点 2 · 通过门控机制，将生成的 DSSIM 图与检测器的高层语义特征融合，提升检测性能。

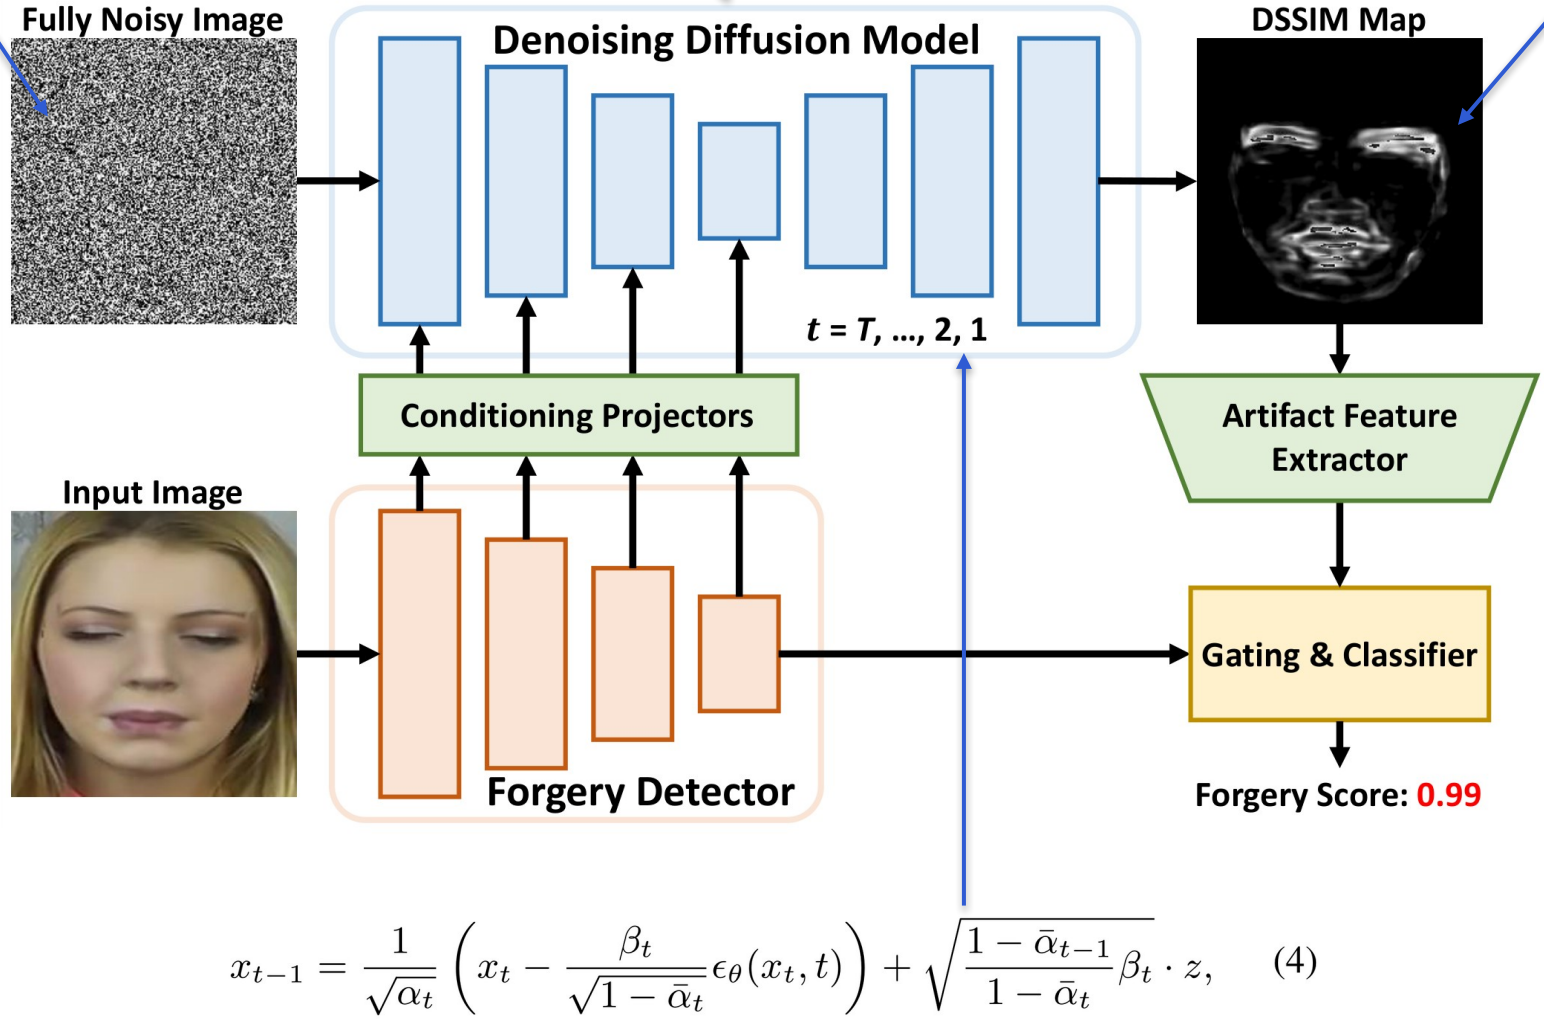
模型图


Fully Noisy Image
Denoising Diffusion Model
t = T, ..., 2, 1
DSSIM Map
Conditioning Projectors
Artifact Feature Extractor
Input Image
Forgery Detector
Gating & Classifier
Forgery Score: 0.99


Conditioning Projectors
Norm
Conv2D
SiLU
Conv2D
Resize
Conv2D
×N
Artifact Feature Extractor
Conv2D
Norm
SiLU
Pooling
Resize
×N
Gating & Classifier
Sigmoid
Head
Forgery Score

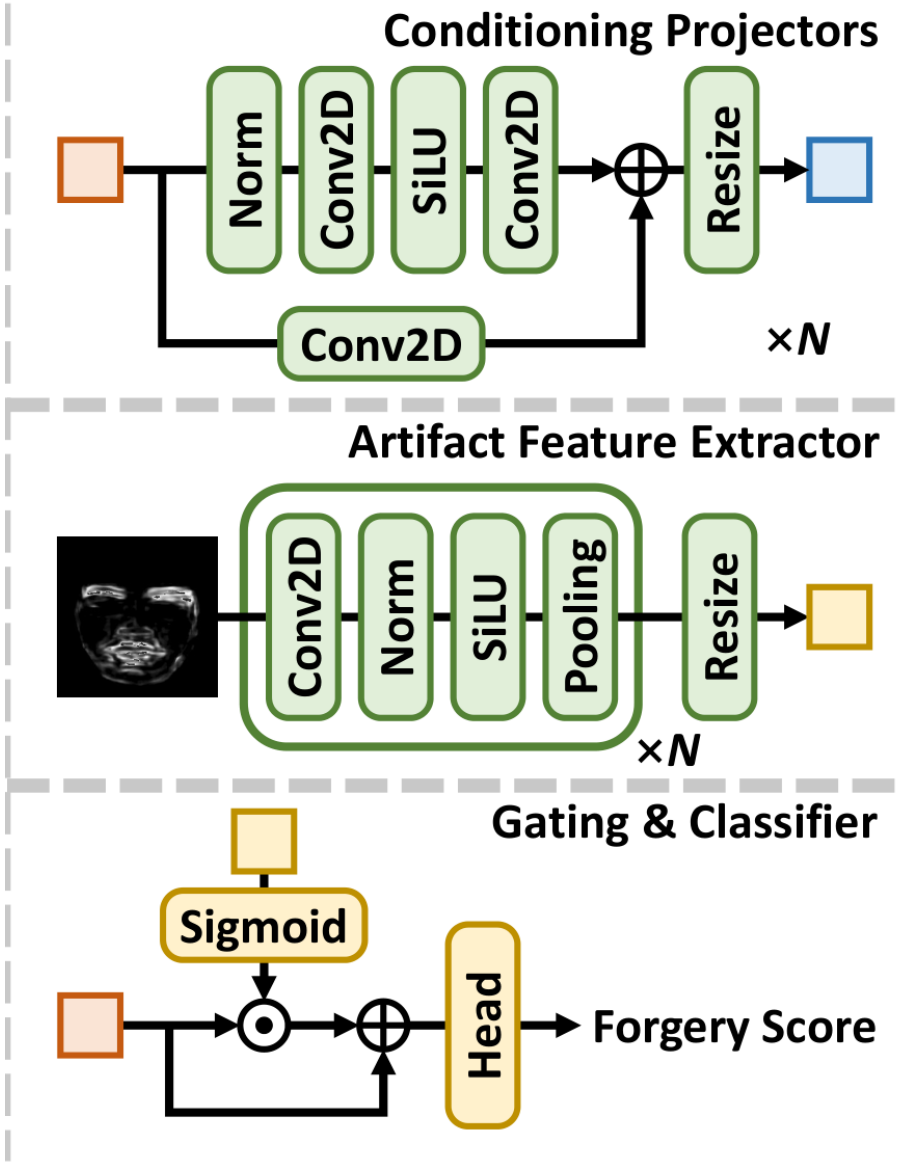
模型图

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, \quad (2) \qquad \mathcal{L}_{\text{MSE}} = \mathbb{E}_{x_0,\epsilon,t}\left[\|\epsilon - \epsilon_\theta(x_t, t)\|_2^2\right]. \quad (3) \qquad \text{DSSIM}(x, y) = 1 - \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)}. \quad (1)$$



$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}}\epsilon_\theta(x_t, t)\right) + \sqrt{\frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t}\beta_t} \cdot z, \quad (4)$$

模型图



阶段一：冻结检测器，用 $\mathcal{L}_{\text{MSE}}$（式 (3)）训练条件投影器与扩散模型

阶段二：冻结检测器、投影器与扩散模型，用交叉熵 $\mathcal{L}_{\text{CE}}$ 训练伪影特征提取器与分类头

$$\text{Score} = \mathcal{H}\left(\sigma\left(\mathcal{E}(M_{DSSIM})\right) \odot F_{det} + F_{det}\right), \quad (5)$$

检测性能对比

Method	Venue	Localization		Test Set AUC (%) ↑			
		Mask	DSSIM	CDF2	DFDC	DFDCP	FFIW
DCL [38]	AAAI 2022	✗	✗	82.30	-	76.71	71.14
SBI [36]	CVPR 2022	✗	✗	93.18	72.42	86.15	84.83
F^2Trans [27]	TIFS 2023	✗	✗	89.87	-	76.15	-
SeeABLE [19]	ICCV 2023	✗	✗	87.30	75.90	86.30	-
LAA-Net [28]	CVPR 2024	✗	✗	95.40	-	86.94	-
RAE [44]	ECCV 2024	✗	✗	95.50	80.20	89.50	-
FreqBlender [62]	NeurIPS 2024	✗	✗	94.59	74.59	87.56	86.14
UDD [7]	AAAI 2025	✗	✗	93.10	81.20	88.10	-
DFD-FCG [8]	CVPR 2025	✗	✗	95.00	81.81	-	-
Effort* [52]	ICML 2025	✗	✗	<u>95.73</u>	<u>84.78</u>	90.42	<u>88.53</u>
LRL* [2]	AAAI 2021	✗	✓	91.70	76.66	81.18	82.00
PCL+I2G [61]	ICCV 2021	✓	✗	90.03	67.52	74.37	-
LiSiam* [47]	TIFS 2022	✗	✓	90.36	72.59	82.06	76.52
AUNet [1]	CVPR 2023	✓	✗	92.77	73.82	86.16	81.45
Delocate [13]	IJCAI 2024	✓	✗	91.30	-	84.00	-
KFD [55]	ICML 2025	✓	✗	94.71	79.12	<u>91.81</u>	-
DiffusionFF (Ours)	-	✗	✓	**97.24**	**85.05**	**92.56**	**88.56**

DiffusionFF 在 CDF2、DFDC、DFDCP、FFIW 四个跨数据集测试中 AUC 均为最高，检测泛化能力最强。

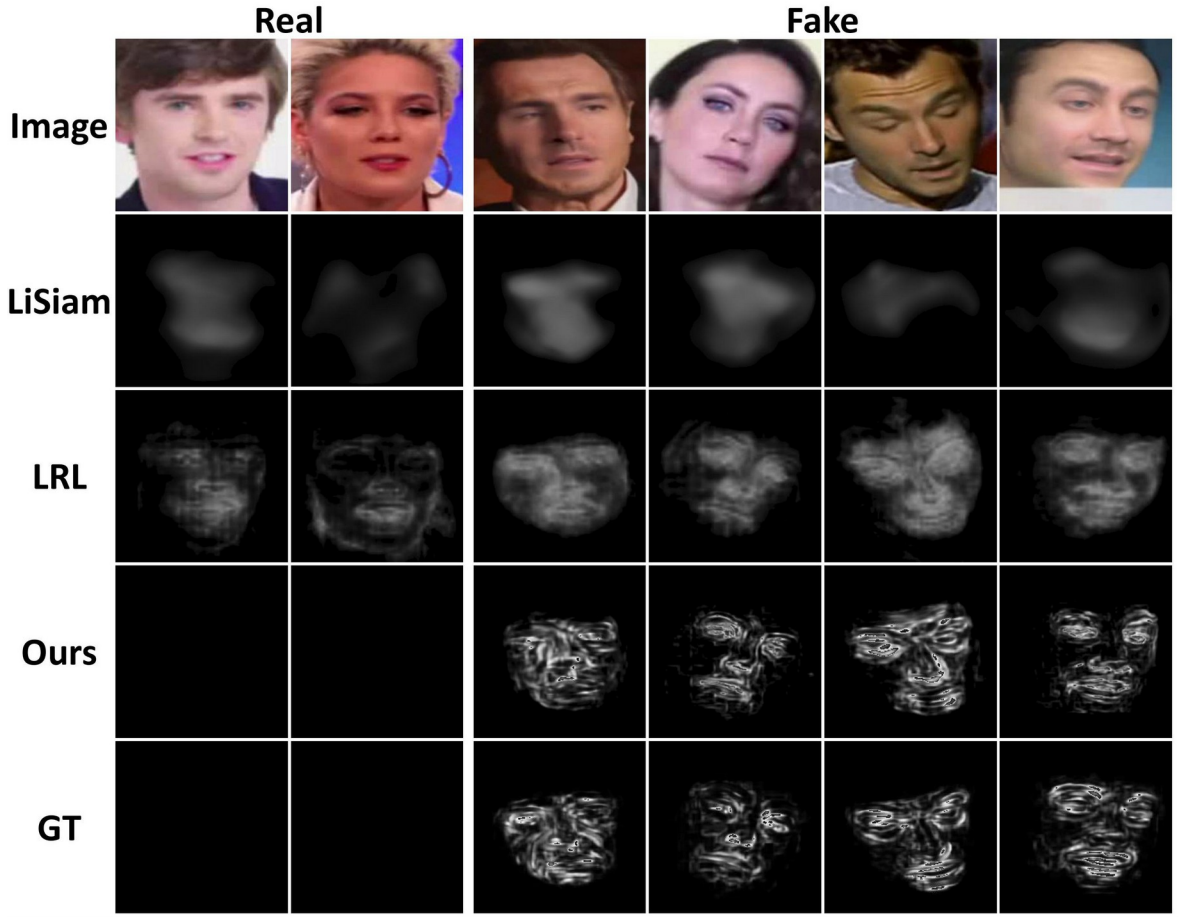
定位性能对比

Dataset	Method	Evaluation Metrics			
		PSNR↑	SSIM↑	LPIPS↓	FID↓
CDF2	LiSiam [47]	21.985	0.367	0.464	256.201
	LRL [2]	20.801	0.422	0.455	258.674
	DiffusionFF	**30.697**	**0.546**	**0.376**	**98.982**
FFIW	LiSiam [47]	23.689	0.421	0.446	284.271
	LRL [2]	23.999	0.460	0.409	248.781
	DiffusionFF	**32.828**	**0.529**	**0.394**	**191.798**

(a) 跨数据集 DSSIM 图质量（表 2）

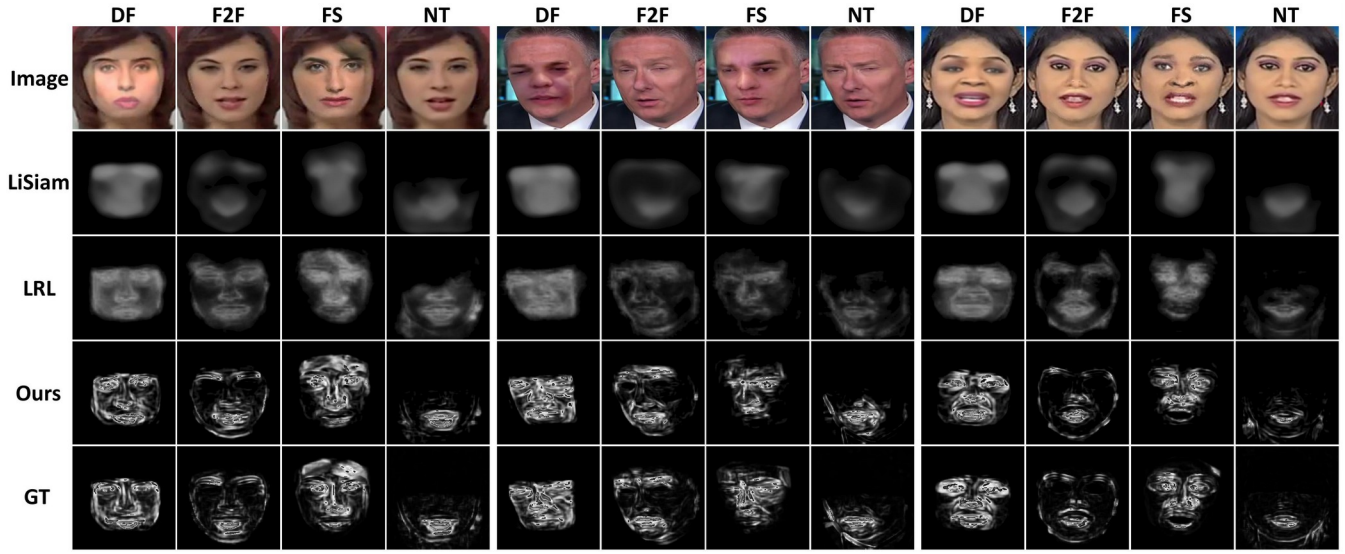
· 在 CDF2 和 FFIW 上，DiffusionFF 的 PSNR、SSIM、LPIPS、FID 四项指标均优于 LiSiam 和 LRL。

· 真实人脸输出全黑图，与 GT 一致；伪造人脸的痕迹细节最接近 GT。

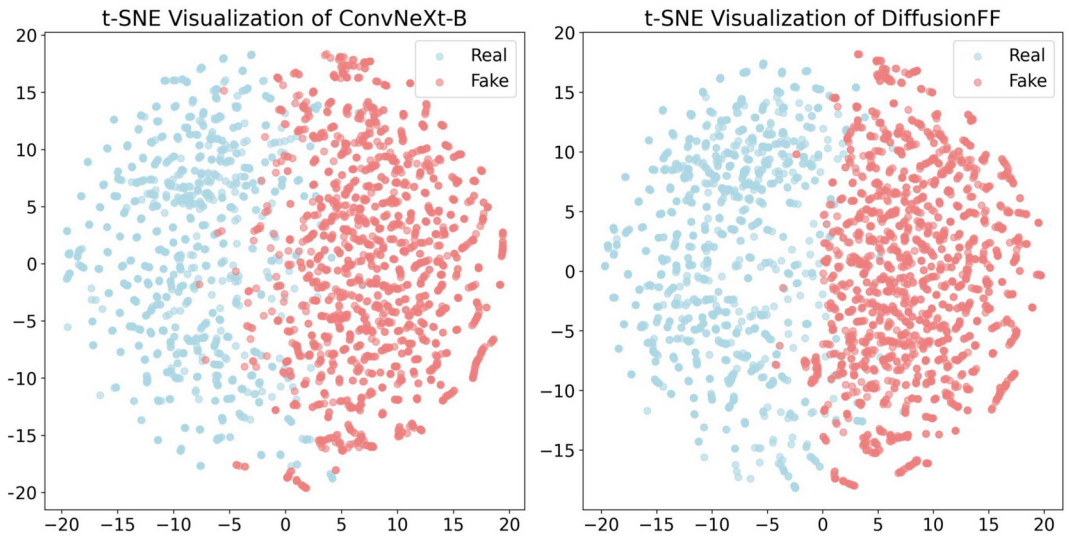


(b) CDF2 上的 DSSIM 图估计结果（图 4）

DiffusionFF 学到了什么



(a) FF++ 上的 DSSIM 图估计结果（图 5）



(b) CDF2 上特征的 t-SNE 可视化（图 6）

· DiffusionFF 生成的 DSSIM 图能精细定位伪造痕迹，与 GT 最接近。

· 不同伪造方法的痕迹位置不同，例如 NT 只修改嘴部，模型也只在嘴部附近标出痕迹。

· 融合 DSSIM 图后，真实与伪造样本的特征分得更开，检测更容易。

消融实验

Method	Evaluation Metrics			
	PSNR↑	SSIM↑	LPIPS↓	FID↓
Direct Regression	24.341	0.584	0.252	172.213
Latent-Space Diffusion	24.228	0.680	0.217	56.384
Final-Stage Cond.	26.154	0.711	0.204	43.812
Decoder Cond.	26.253	0.716	0.202	46.329
The Proposed	**26.376**	**0.718**	**0.198**	**43.093**

(a) 扩散模型设计的消融（表 5， FF++ ）

Method	Test Set AUC (%) ↑				Avg.
	CDF2	DFDC	DFDCP	FFIW	
Addition	95.79	84.68	91.56	88.38	90.10
Hadamard Product	96.46	84.53	91.37	88.40	90.19
Concatenation	96.66	85.00	91.87	**89.01**	90.64
Cross-Attention	97.19	84.91	92.26	88.46	90.71
Gating Mechanism	**97.24**	**85.05**	**92.56**	88.56	**90.85**

(b) 融合方式的消融（表 6，跨数据集 AUC ）

- 替换任一设计后整体性能都会下降，说明各设计均有贡献。
- 扩散生成：改用直接回归时 FID 从 43.09 升至 172.21， DSSIM 图质量下降最明显。
- 条件设计：多尺度条件、注入 U-Net 编码器，均优于只用最后阶段或注入解码器。
- 门控融合：平均 AUC 为 90.85，高于相加、逐元素相乘、拼接和交叉注意力。

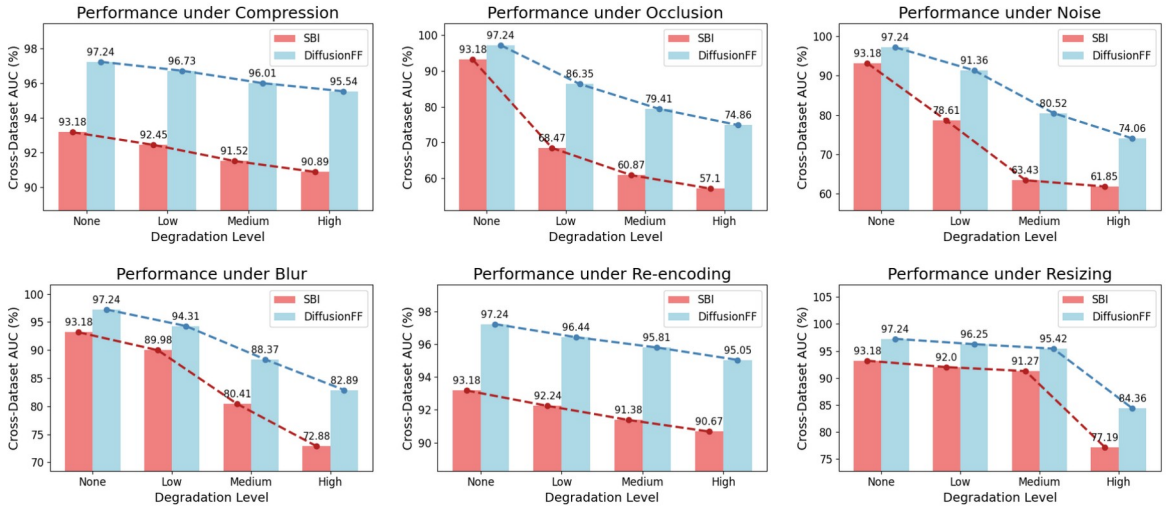
不同检测器上的泛化能力

Method	Params	Test Set AUC (%) ↑			
		CDF2	DFDC	DFDCP	FFIW
EfficientNet-B4	19M	93.18	72.42	86.15	84.83
+ DiffusionFF	32M	95.54	82.19	89.03	86.37
Swin-B	88M	95.59	82.81	89.74	85.38
+ DiffusionFF	101M	96.93	84.54	90.78	87.01
ConvNeXt-B	89M	96.08	84.26	90.20	87.67
+ DiffusionFF	102M	**97.24**	**85.05**	**92.56**	**88.56**

· 接入 EfficientNet-B4 、 Swin-B 、 ConvNeXt-B 后，四个跨数据集测试的 AUC 全部提升；

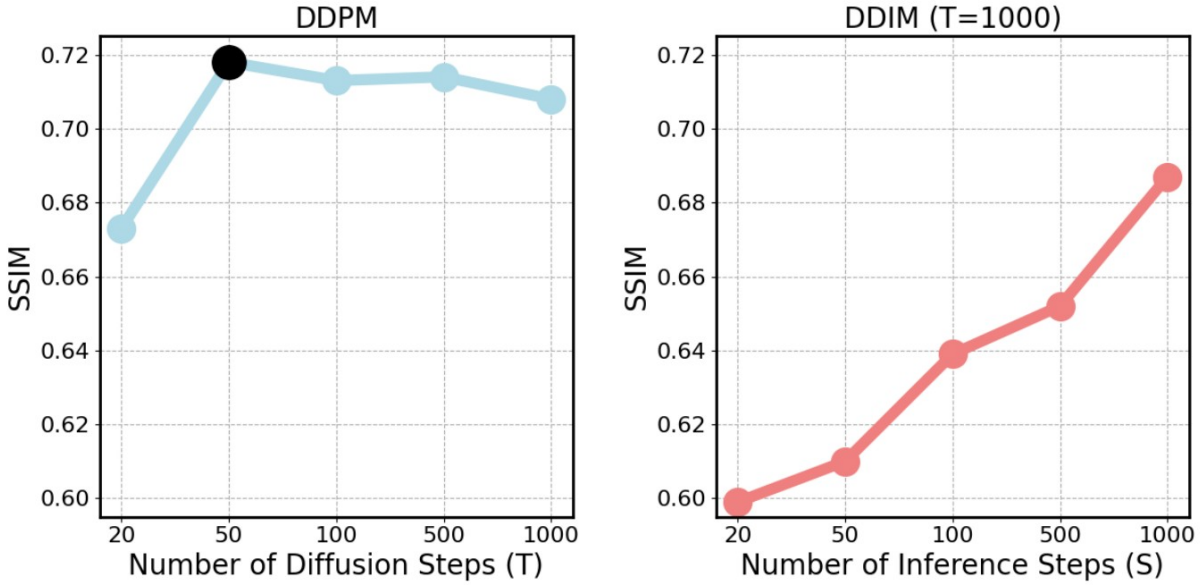
· DiffusionFF 可作为即插即用模块，同时提供可解释的定位图。

不同干扰下的鲁棒性

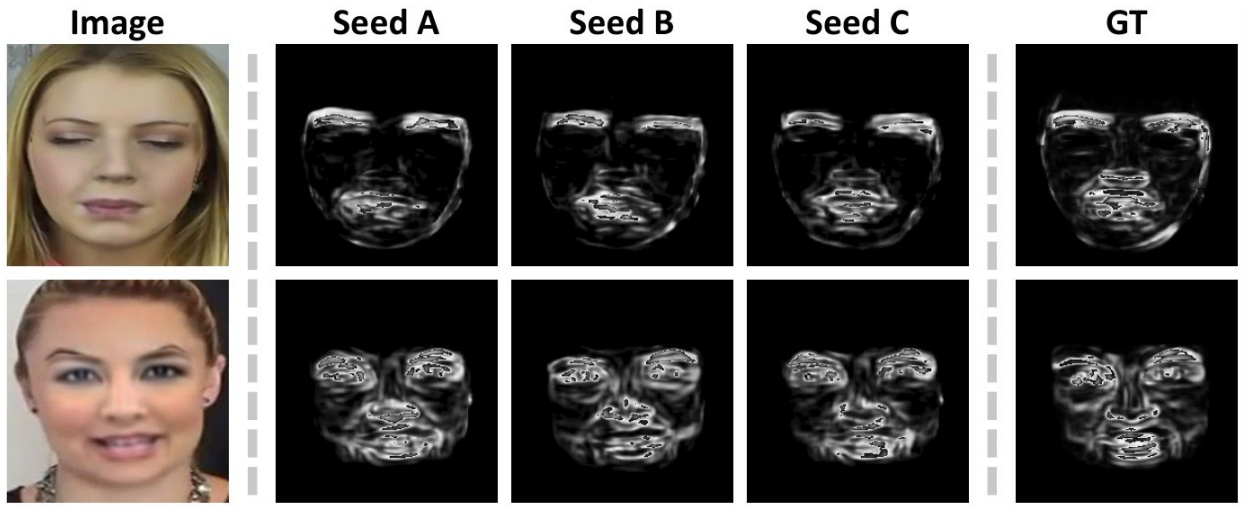


· 在压缩、遮挡、噪声、模糊、重编码、缩放六种干扰下，DiffusionFF 的 AUC 始终高于 SBI，且性能下降更小。

超参数敏感性分析



(a) 扩散步数对 DSSIM 图质量（SSIM）的影响（补充材料图 2）



(b) 不同随机种子生成的 DSSIM 图（补充材料图 3）

扩散步数 T = 50 时 DSSIM 图质量最高；不同随机种子生成的定位图基本一致。