DiffusionFF: A Diffusion-based Framework for Joint Face Forgery Detection and Fine-Grained Artifact Localization

CVPR 2026

背景

1、**人脸伪造检测**： Deepfake 技术可以用 AI 换脸、改表情。检测任务是输入一张人脸，判断真假（二分类），输出 0 ～ 1 的伪造分数，越接近 1 越可能是假的。

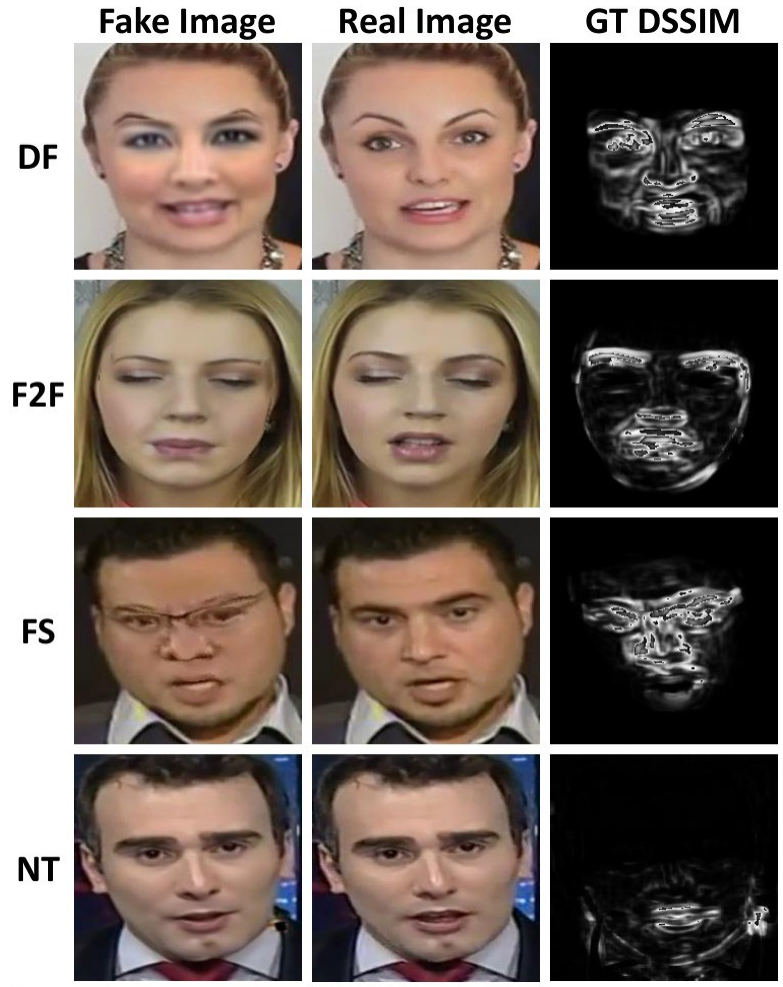
2、**伪影定位**：指出“哪里是假的”，作为判断依据，提高可解释性。

· Mask： 黑白掩码，只圈出大致的篡改区域，较粗；

· DSSIM 图：灰度图，越亮表示与原始真脸差异越大，可精细到像素级。 DSSIM = 1 − SSIM （结构相似度）。

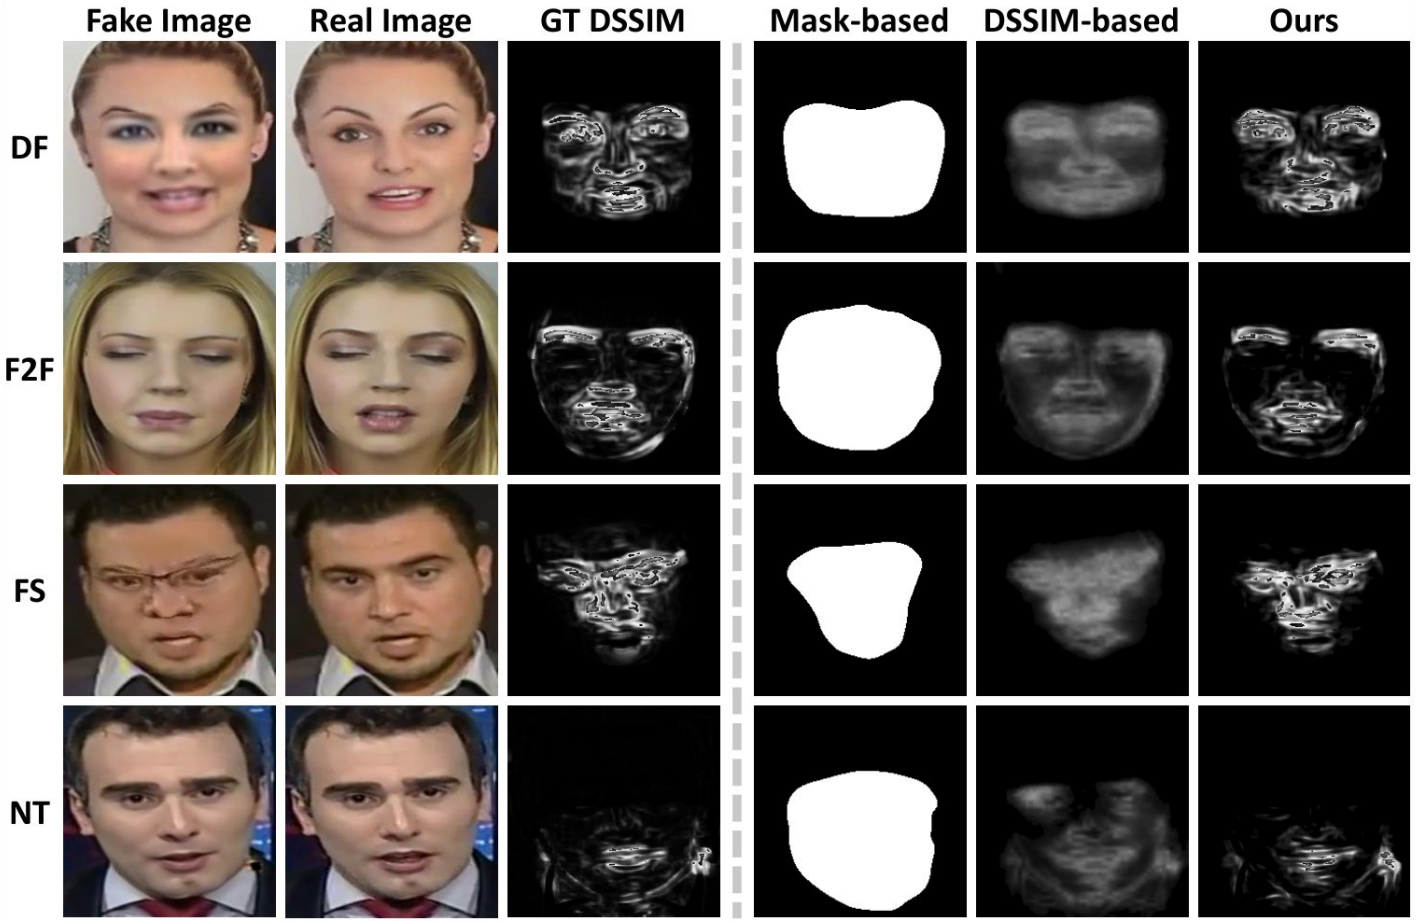
3、 **GT DSSIM （标准答案）**： 用逐像素对齐的真脸和假脸计算得到；真脸的 GT 为全黑图。实际使用时只有一张待测人脸， DSSIM 图只能由模型估计。

4、**论文要解决的问题**：只给一张人脸，同时判断真假、精细估计 DSSIM 图，并让 DSSIM 图反过来帮助检测。



论文 Figure 1 左三列： Fake Image 假脸 / Real Image 对应真脸 / GT DSSIM 标准答案； DF 、 F2F 、 FS 、 NT 为 FF++ 的四种伪造方法

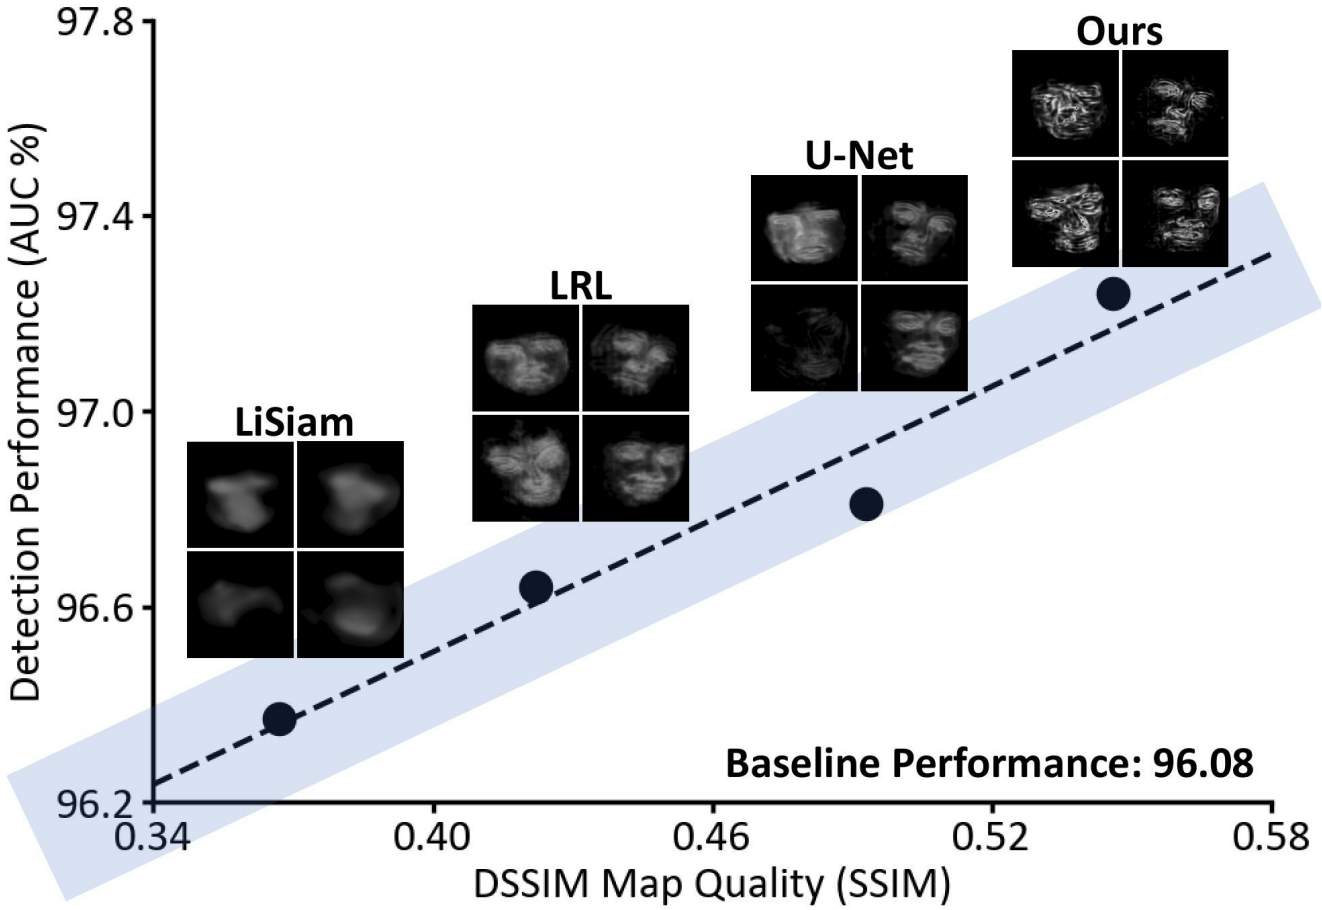
动机 1 · 现有定位方法要么太粗（Mask），要么太糊（DSSIM 直接回归）。



论文 Figure 1： 与基于 Mask 的方法、已有基于 DSSIM 的方法的定位结果对比（FF++， DF / F2F / FS / NT 四种伪造方法）

创新点 1 · 预训练伪造检测器作“伪影编码器”，去噪扩散模型作“伪影解码器”，以多尺度伪造特征为条件，逐步生成精细的 DSSIM 图。

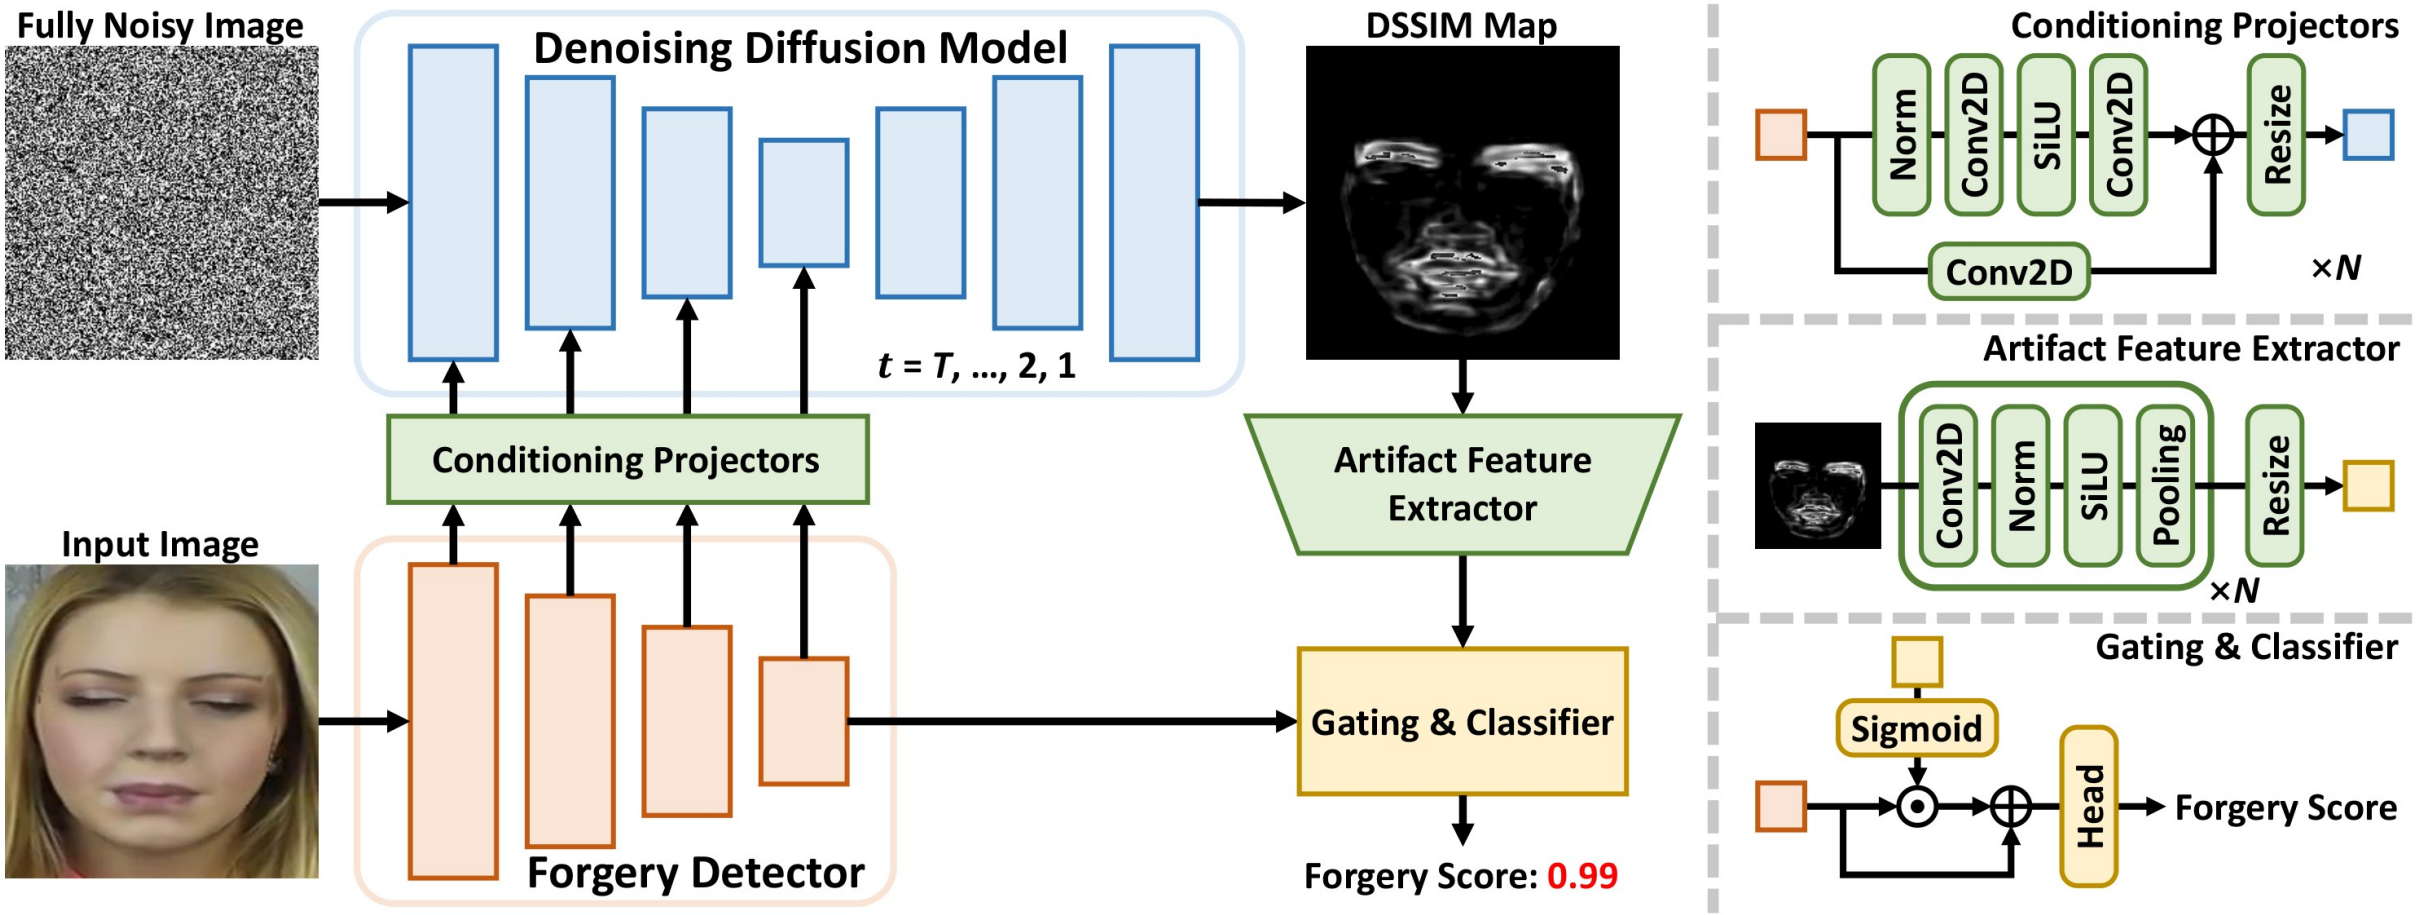
动机 2 · DSSIM 图估计得越准，融合后的检测性能越高。



论文 Figure 2： 横轴为估计 DSSIM 图的质量（与 GT 的 SSIM），纵轴为检测 AUC； Baseline 96.08 为只用检测器的结果

创新点 2 · 用伪影特征提取器把 DSSIM 图编码成特征，再通过门控机制与检测器的高层特征融合，提升检测性能。

模型图

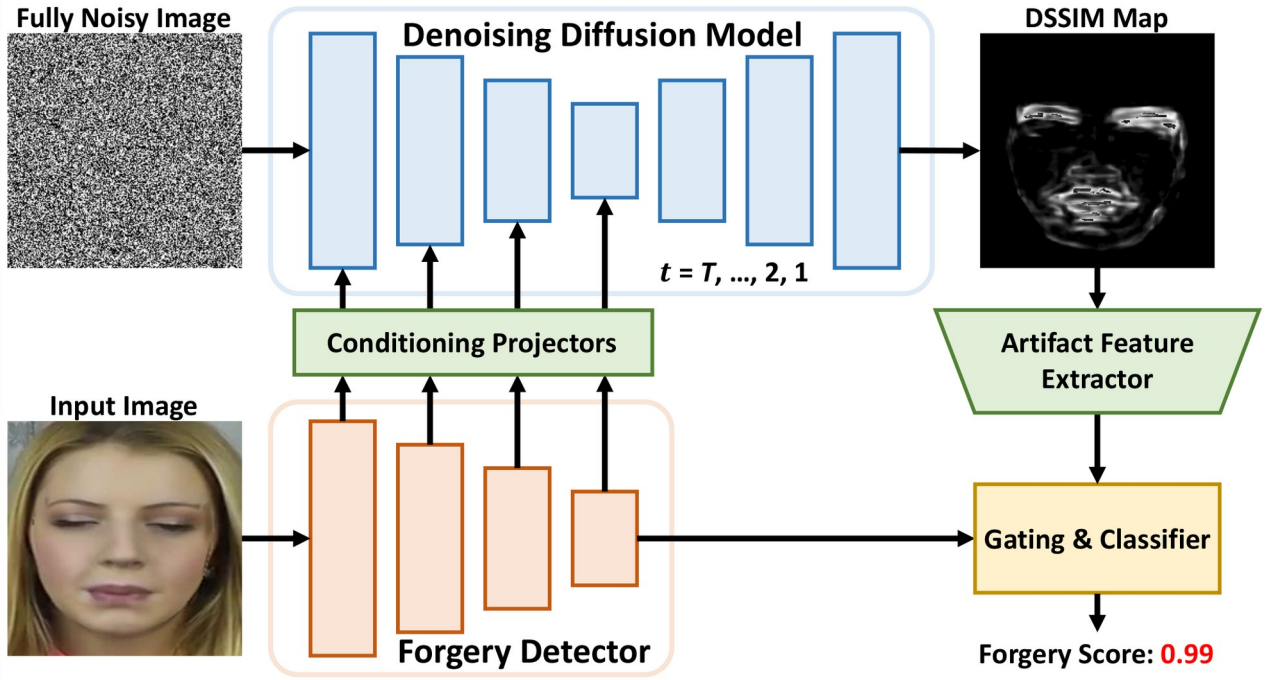


论文 Figure 3： DiffusionFF 框架总览

· 左：主图（整体流程）；右：三个模块的内部结构（ Conditioning Projectors / Artifact Feature Extractor / Gating & Classifier ），N = 4 为检测器的阶段数

· 输入：一张人脸（ Input Image ） 输出①： DSSIM Map （哪里是假的） 输出②： Forgery Score （是不是假的）

模型图 · 主图流程



· 唯一的输入是 Input Image； Fully Noisy Image 由程序随机生成

· 检测器、投影器只算 1 次； U-Net 循环去噪 50 次

· 每帧耗时：检测器 0.01 s，完整流程 0.34 s （补充材料）

① **Input Image → Forgery Detector**： ConvNeXt-B，已在 FF++ 上预训练并冻结； 4 个阶段输出 4 个尺度的特征，最后一阶段特征记为 F_{det}

② **Conditioning Projectors**：把 4 组特征转换成 U-Net 前 4 层需要的通道数和尺寸，注入 U-Net

③ **Fully Noisy Image**：随机噪声图 x_T，画图的起点

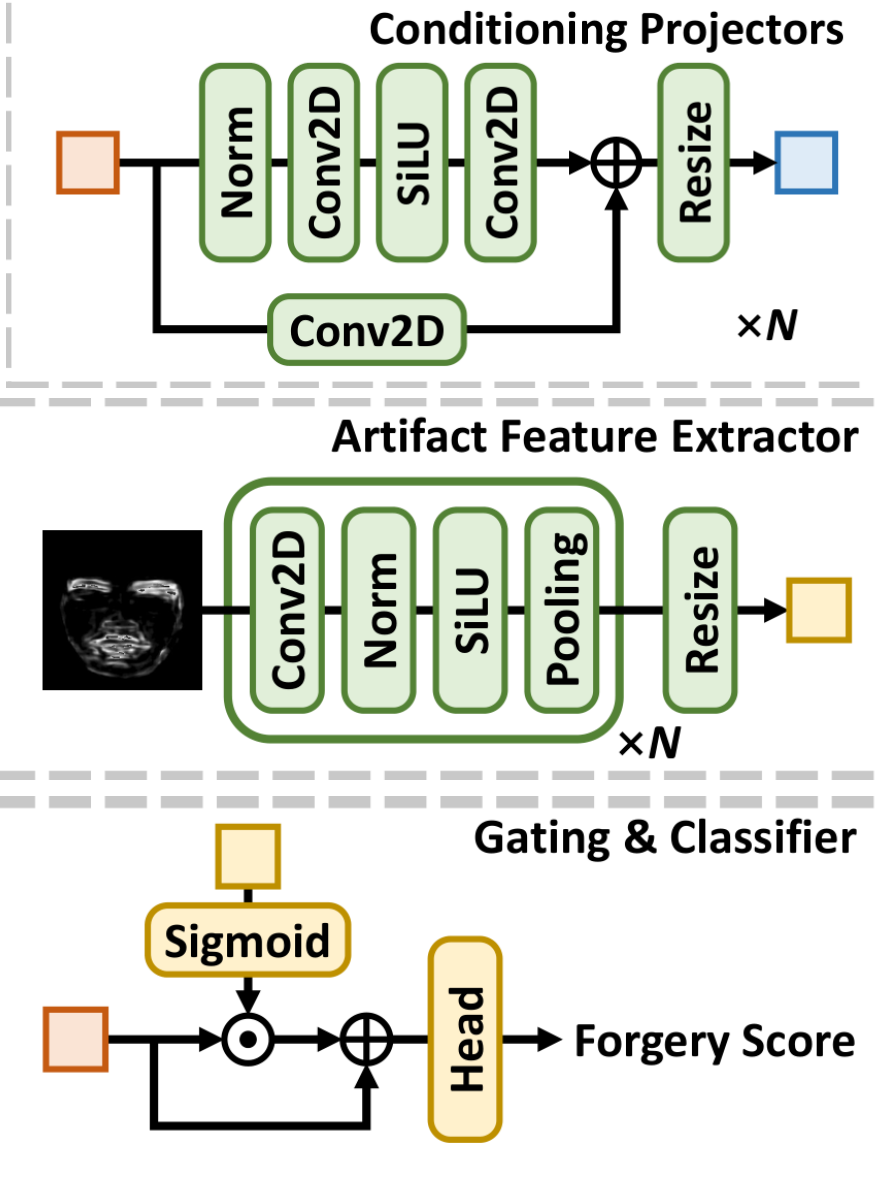
④ **Denoising Diffusion Model**： 7 阶段 U-Net，按 t = T, …, 2, 1 循环去噪， T = 50

⑤ **DSSIM Map**：输出①，越亮表示篡改越明显，真脸接近全黑

⑥ **Artifact Feature Extractor**：把 DSSIM 图编码成与 F_{det} 形状相同的伪影特征

⑦ **Gating & Classifier**：伪影特征与 F_{det} 门控融合，分类头输出 Forgery Score （输出②）

模型图 · 右侧三个小图



小图 1　Conditioning Projectors （条件投影器）

流程：Norm → Conv2D → SiLU → Conv2D （主路）＋ Conv2D （捷径）→ ⊕ 相加 → Resize

作用：把检测器某一阶段的特征（橙）转换成 U-Net 对应层可用的特征（蓝）；×N：每个阶段一个，共 4 个

小图 2　Artifact Feature Extractor （伪影特征提取器）

流程：[Conv2D → Norm → SiLU → Pooling] × N → Resize

作用：把 DSSIM 图逐步缩小、增加通道，变成与 F_{det} 形状相同的伪影特征（黄）

小图 3　Gating & Classifier （门控与分类器）

流程：伪影特征（黄）→ Sigmoid → 与 F_{det} （橙）逐元素相乘 ⊙ → 加回 F_{det} ⊕ → Head → Forgery Score

作用：用 DSSIM 信息有选择地放大检测器特征，即公式 (5)

模型图 · 小图中的基础组件

Conv2D （二维卷积）：小窗口在图上滑动，窗口内的数与权重相乘再求和；输出通道数 = 卷积核的组数

Norm （归一化）：减去平均值、除以标准差，把数值拉到 0 附近，训练更稳定

激活函数：卷积只做乘法和加法（线性运算），多层叠起来仍等于一层；激活函数引入“拐弯”（非线性），网络才能学复杂规律

ReLU： $\mathrm{ReLU}(x) = \max(0, x)$；例： $|x| = \mathrm{ReLU}(x) + \mathrm{ReLU}(-x)$

SiLU： $\mathrm{SiLU}(x) = x \cdot \sigma(x)$，正数基本保留、负数压向 0；$\mathrm{SiLU}(2) \approx 1.76$， $\mathrm{SiLU}(-2) \approx -0.24$

Sigmoid： $\sigma(x) = 1 / (1 + e^{-x})$，输出在 0 ～ 1 之间，用作“门”； $\sigma(-4) \approx 0.02$， $\sigma(0) = 0.5$， $\sigma(4) \approx 0.98$

Pooling （池化）：相邻 2×2 合成 1 个数（取最大或平均），高、宽各减半

Resize：用插值把特征图缩放到指定尺寸

⊕：逐元素相加（残差连接：输出 = 输入 + 加工结果）

⊙：逐元素相乘（Hadamard 积）： $[1, 2, 3] \odot [0.5, 1, 0] = [0.5, 2, 0]$

Head （分类头）：特征 → 一个分数； **×N**：重复 N 次 / 共 N 份， $N = 4$

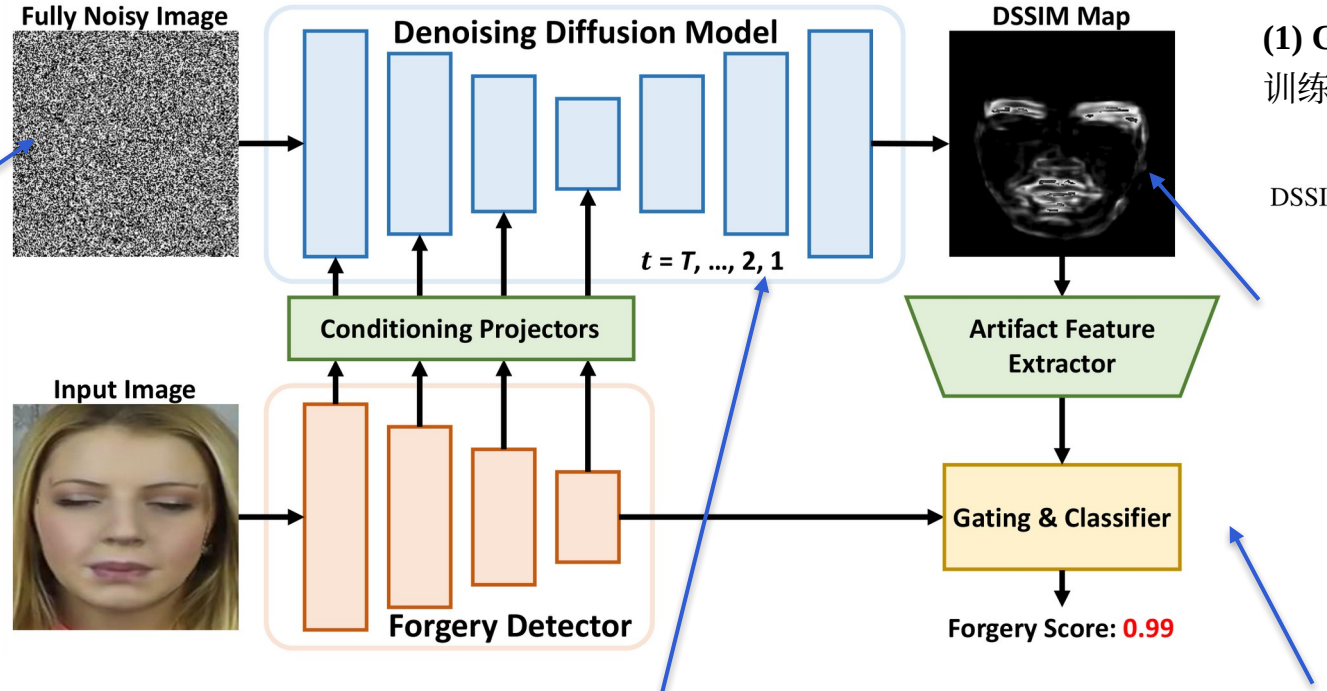
模型图 · 公式与模块的对应

(2) 前向加噪　(3) 训练损失

训练时使用； x_T 即左上角噪声图

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon, \quad (2)$$

$$\mathcal{L}_{\text{MSE}} = \mathbb{E}_{x_0,\epsilon,t}\left[\|\epsilon - \epsilon_\theta(x_t, t)\|_2^2\right]. \quad (3)$$



(1) GT DSSIM 怎么算

训练目标，也是评价标准

$$\text{DSSIM}(x,y) = 1 - \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)}. \quad (1)$$

(4) 反向去噪　推理时使用，　t = T, …, 2, 1　每轮用一次

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon_\theta(x_t, t)\right) + \sqrt{\frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t}\cdot z, \quad (4)$$

(5) 门控融合与分类　推理时使用，输出 Forgery Score

$$\text{Score} = \mathcal{H}\left(\sigma\left(\mathcal{E}(M_{DSSIM})\right) \odot F_{det} + F_{det}\right), \quad (5)$$

· 训练时用 (1)(2)(3)： 算标准答案、给标准答案加噪、训练 U-Net 猜噪声；推理时用 (4)(5)： 循环去噪画出 DSSIM 图、融合并打分

· 易混符号： (1) 的 x、 y 是真脸 / 假脸窗口； (2) ～ (4) 的 x_0、 x_t 是 DSSIM 图及其加噪版本； (1) 的 σ 是方差， (5) 的 σ 是 Sigmoid

公式 (1)： GT DSSIM 图

$$\mathrm{DSSIM}(x,y) = 1 - \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)}. \tag{1}$$

(i, j)：像素位置，第 i 行、第 j 列；窗口逐像素滑动，每个位置算一个值

x：真脸上以 (i, j) 为中心的 7×7 窗口（49 个像素）

y：假脸上同一位置的 7×7 窗口

μ_x、μ_y：窗口内像素的平均值（平均亮度）

σ_x^2、σ_y^2：窗口内像素的方差（明暗起伏，对比度）

σ_{xy}：两个窗口的协方差（纹理是否同步变化）

C_1、C_2：防止分母为 0 的小常数

分式 = SSIM（结构相似度）：第一个因子比较亮度，第二个因子比较对比度和纹理，最大都是 1

DSSIM = 1 − SSIM：完全一样时为 0（黑色），差别越大越亮

例：x = [60, 150, 60, 150]；y 整体亮 30 → DSSIM ≈ 0.03；y 纹理被抹平成 [105, 105, 105, 105] → DSSIM ≈ 0.97

真脸的 GT DSSIM 图 = 全黑图；计算 GT 需要逐像素对齐的真假图对（FF++、CDF2、FFIW 有，DFDC、DFDCP 没有）

公式 (2)： 前向加噪

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, \qquad (2)$$

x_0： 干净的图，本文中是 GT DSSIM 图（不是人脸）

x_t： 加了 t 步噪声后的图； $t = 1, \ldots, T$， $T = 50$

$\varepsilon \sim N(0, I)$： 标准正态噪声，平均值 0、方差 1，各像素独立

β_t： 第 t 步的噪声强度，从 0.02 线性增加到 0.4（补充材料）

$\alpha_t = 1 - \beta_t$： 第 t 步保留的比例

$\bar{\alpha}_t = \alpha_1 \alpha_2 \cdots \alpha_t$（连乘，论文中写作 $\prod$）

$\sqrt{\bar{\alpha}_t}$： 原图系数；**$\sqrt{(1 - \bar{\alpha}_t)}$**： 噪声系数；两者平方和为 1

作用：训练时一步算出任意第 t 步的加噪图

t	$\bar{\alpha}_t$	$\sqrt{\bar{\alpha}_t}$	$\sqrt{(1 - \bar{\alpha}_t)}$	x_t
1	0.980	0.990	0.141	0.721
10	0.567	0.753	0.658	0.273
25	0.047	0.218	0.976	−0.314
50	0.000005	0.002	1.000	−0.498

表中 x_t 以一个像素为例： $x_0 = 0.8$， $\varepsilon = -0.5$

来历：单步加噪 $x_t = \sqrt{\alpha_t}\, x_{t-1} + \sqrt{\beta_t}\, \varepsilon$ 逐步展开；两份独立高斯噪声相加仍是高斯，方差相加： $\alpha_t(1 - \alpha_{t-1}) + (1 - \alpha_t) = 1 - \alpha_t\alpha_{t-1}$

公式 (3)：训练损失

$$\mathcal{L}_{\text{MSE}} = \mathbb{E}_{x_0,\epsilon,t}\left[\|\epsilon - \epsilon_\theta(x_t, t)\|_2^2\right]. \qquad (3)$$

L_{MSE}：均方误差损失（Mean Squared Error），越小越好

ε：公式 (2) 中真正加进去的噪声

$\varepsilon_\theta(x_t, t)$：去噪网络（U-Net）根据 x_t 和 t 猜出的噪声；θ 为网络全部可学习的参数

$\|\cdot\|_2^2$：L2 范数的平方，逐像素求差、平方、求和

$\mathbb{E}_{x0,\varepsilon,t}$（空心 E）：期望，即求平均；$x_0$ 取自训练集，ε 随机抽取，t 在 1 ～ T 中随机选

论文省略了条件：实际为 $\varepsilon_\theta(x_t, t, c)$，c 是条件投影器送来的检测器特征

训练一步：

1. 取人脸及其 GT DSSIM 图 x_0（真脸配全黑图）
2. 人脸进检测器（冻结）→ 投影器 → 条件 c
3. 随机选 t、抽 ε，按公式 (2) 得到 x_t
4. U-Net 输入 x_t、t、c，输出 ε_θ
5. 按公式 (3) 算损失，更新投影器和 U-Net

例：ε = [0.5, −1.0, 0.2]，ε_θ = [0.3, −0.6, 0.5] → 平方和 0.29

为什么猜噪声就够了：$x_0 = (x_t - \sqrt{(1-\bar{\alpha}_t)}\,\varepsilon) / \sqrt{\bar{\alpha}_t}$

公式 (4)： 反向去噪

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right) + \sqrt{\frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t} \beta_t} \cdot z, \tag{4}$$

$x_t \to x_{t-1}$： 每用一次，图干净一点；从 x_T（纯噪声）用到 $t = 1$，得到的 x_0 就是 DSSIM 图

$\epsilon_\theta(x_t, t)$： U-Net 猜出的噪声（省略了条件 c）

$\beta_t / \sqrt{(1 - \bar{\alpha}_t)}$： 这一步减掉多少猜出来的噪声

$1 / \sqrt{\alpha_t}$： 放大系数，抵消前向过程中乘上的 $\sqrt{\alpha_t}$

$\sqrt{((1 - \bar{\alpha}_{t-1}) / (1 - \bar{\alpha}_t) \cdot \beta_t)} \cdot z$： 新加的随机项， $z \sim N(0, I)$，只在 $t > 1$ 时加

前半： x_{t-1} 最可能的样子（均值）；**后半**：保留随机性，避免输出平均出来的糊图

t	$1 / \sqrt{\alpha_t}$	$\beta_t / \sqrt{(1 - \bar{\alpha}_t)}$	随机项系数
50	1.291	0.400	0.632
10	1.048	0.137	0.280
1	1.010	0.141	0（不加）

例（t = 10）： $x_{10} \approx 0.273$， U-Net 猜 $\varepsilon_\theta = -0.45 \to x_9 \approx 1.048 \times (0.273 + 0.137 \times 0.45) + 0.280\ z \approx 0.351 + 0.280\ z$

对应模型图： x_T = Fully Noisy Image；循环 = t = T, …, 2, 1；最终 x_0 = DSSIM Map

公式 (5)：门控融合与分类

$$\text{Score} = \mathcal{H}\Big(\sigma\left(\mathcal{E}(M_{DSSIM})\right) \odot F_{det} + F_{det}\Big), \quad (5)$$

M_{DSSIM}：扩散模型估计的 DSSIM 图（公式 (4) 的输出）

$\mathcal{E}$：伪影特征提取器（小图 2），$\mathcal{E}(M_{DSSIM})$ 与 F_{det} 形状相同

σ： Sigmoid，把伪影特征压到 0 ～ 1，作为“门”

F_{det}：检测器最后一个阶段的高层语义特征

⊙：逐元素相乘；**+ F_{det}**：残差，加回原特征

$\mathcal{H}$：分类头，输出 Score （0 ～ 1，越接近 1 越可能是假的）

等价形式：$F_{det} \odot (1 + \sigma(\mathcal{E}(M_{DSSIM})))$，每个位置放大 1 ～ 2 倍

	位置 1	**位置 2**	**位置 3**
F_{det}	3	−1	2
$\mathcal{E}(M_{DSSIM})$	2.2	−2.2	0
门 σ(·)	0.9	0.1	0.5
门 ⊙ F_{det}	2.7	−0.1	1.0
+ F_{det}	5.7	−1.1	3.0

第二阶段的损失（交叉熵）： $L_{CE} = -[y \log p + (1 - y) \log(1 - p)]$； y 为标签（假 = 1，真 = 0），p 为 Score

例：假脸 p = 0.99 → 0.01；真脸却给出 p = 0.99 → 4.61

训练策略：两阶段训练

	阶段零：检测器预训练	阶段一：学画图	阶段二：学判断
训练	ConvNeXt-B 检测器	条件投影器 + U-Net	伪影特征提取器 + 分类头
冻结	—	检测器	检测器、投影器、 U-Net
损失	判断真假	公式 (3)	交叉熵
设置	200 轮， batch 64 ， lr 5×10^{-5} ，第 100 轮起线性衰减	100 轮， batch 96 ， lr 1×10^{-4} ，余弦衰减，T = 50	5 轮， batch 128 ， lr 5×10^{-5} （固定）

· **为什么分两阶段**：画 DSSIM 图和判断真假差别很大，一起训练两者都会变差（补充材料 Table 2 ）

· **为什么检测器要预训练并冻结**：从零联合训练会坍塌，模型学成“永远输出全黑图”（真脸的 GT 全黑，损失为 0 ）

· **第二阶段用估计图，不用 GT 图**：改用 GT 图时 CDF2 的 AUC 为 96.72 ，低于 97.24 （数值分布不匹配）

· **SBI**： 把真脸轻微变换后再与自身融合，造出伪造样本；它与真脸天然对齐，可以计算 GT DSSIM ；训练数据为 FF++ + SBI 样本

实验设置

数据集

· FF++： 训练 + 同数据集测试； 1000 个真视频、 4000 个假视频（ DF 、 F2F 、 FS 、 NT ）

· 跨数据集测试（训练时未见过）： CDF2 （名人视频，伪造质量高）、 DFDC 与 DFDCP （含压缩、噪声等干扰）、 FFIW （多人场景）

对比方法

· 16 个： 10 个只做检测， 6 个检测 + 定位；带 * 的为作者复现

实现

· 检测器 ConvNeXt-B； U-Net 7 阶段，通道 [64, 64, 128, 256, 128, 64, 64]； T = 50； GT 窗口 7×7

· 每个视频测试 32 帧，视频分数 = 各帧分数的平均

评价指标（↑ 越高越好，↓ 越低越好）

· **AUC** （检测）： ROC 曲线下的面积；等于随机抽一真一假，假脸得分更高的概率； 50% 为瞎猜

· **PSNR** （定位）： $10 \cdot \log_{10}($ 最大值 ^{2} / 均方误差 $)$ ，单位 dB； 高 10 dB ≈ 误差降为 1/10

· **SSIM** （定位）： 估计图与 GT 图的结构相似度，越接近 1 越好

· **LPIPS** （定位）： 用神经网络特征比较两张图的感知差异

· **FID** （定位）： 比较一批估计图与一批 GT 图的整体分布距离，对模糊敏感

性能对比 · 跨数据集检测（表 1）

Method	Venue	Localization		Test Set AUC (%) ↑			
		Mask	DSSIM	CDF2	DFDC	DFDCP	FFIW
DCL [38]	AAAI 2022	✗	✗	82.30	-	76.71	71.14
SBI [36]	CVPR 2022	✗	✗	93.18	72.42	86.15	84.83
F^2Trans [27]	TIFS 2023	✗	✗	89.87	-	76.15	-
SeeABLE [19]	ICCV 2023	✗	✗	87.30	75.90	86.30	-
LAA-Net [28]	CVPR 2024	✗	✗	95.40	-	86.94	-
RAE [44]	ECCV 2024	✗	✗	95.50	80.20	89.50	-
FreqBlender [62]	NeurIPS 2024	✗	✗	94.59	74.59	87.56	86.14
UDD [7]	AAAI 2025	✗	✗	93.10	81.20	88.10	-
DFD-FCG [8]	CVPR 2025	✗	✗	95.00	81.81	-	-
Effort* [52]	ICML 2025	✗	✗	<u>95.73</u>	<u>84.78</u>	90.42	<u>88.53</u>
LRL* [2]	AAAI 2021	✗	✓	91.70	76.66	81.18	82.00
PCL+I2G [61]	ICCV 2021	✓	✗	90.03	67.52	74.37	-
LiSiam* [47]	TIFS 2022	✗	✓	90.36	72.59	82.06	76.52
AUNet [1]	CVPR 2023	✓	✗	92.77	73.82	86.16	81.45
Delocate [13]	IJCAI 2024	✓	✗	91.30	-	84.00	-
KFD [55]	ICML 2025	✓	✗	94.71	79.12	<u>91.81</u>	-
DiffusionFF (Ours)	-	✗	✓	**97.24**	**85.05**	**92.56**	**88.56**

DiffusionFF 在 4 个未见过的数据集上 AUC 均为第一： CDF2 97.24 、 DFDC 85.05 、 DFDCP 92.56 、 FFIW 88.56

✓/✗ ： 能否输出 Mask / DSSIM 定位； * 为作者复现；粗体为第一，下划线为第二；横线上方为只做检测的方法

性能对比 · 跨数据集定位（表 2、图 4）

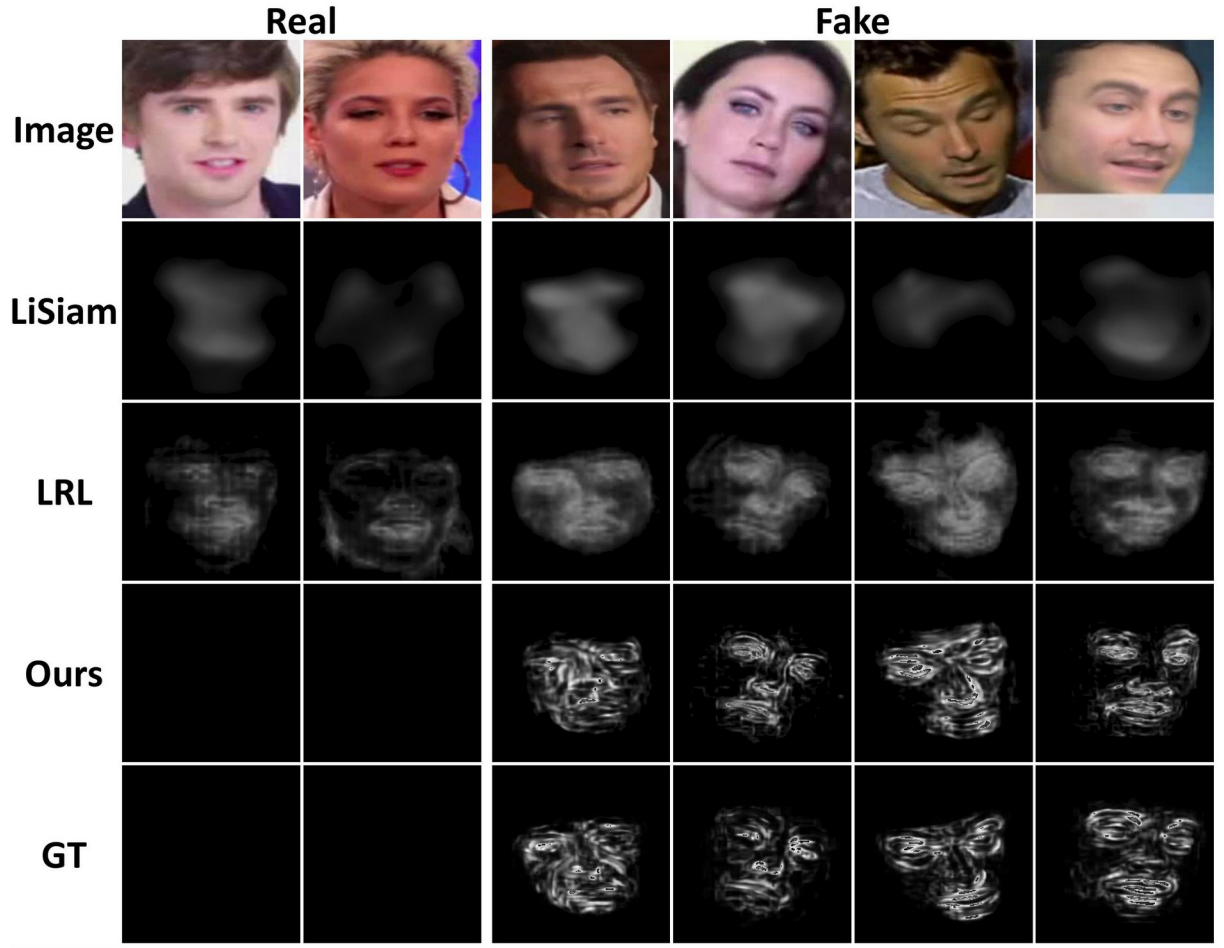
Dataset	Method	Evaluation Metrics			
		PSNR↑	SSIM↑	LPIPS↓	FID↓
CDF2	LiSiam [47]	21.985	0.367	0.464	256.201
	LRL [2]	20.801	0.422	0.455	258.674
	DiffusionFF	**30.697**	**0.546**	**0.376**	**98.982**
FFIW	LiSiam [47]	23.689	0.421	0.446	284.271
	LRL [2]	23.999	0.460	0.409	248.781
	DiffusionFF	**32.828**	**0.529**	**0.394**	**191.798**

· **表 2**： CDF2 、 FFIW 上四项指标全部领先（ DFDC 、 DFDCP 没有对齐的图对，无 GT ）

· CDF2： PSNR 30.70 ，对手 21.99 / 20.80 ； FID 98.98 ，对手 256.20 / 258.67

· **图 4**： 行 = 输入、 LiSiam 、 LRL 、本文、 GT ； 左 2 列为真脸，右 4 列为假脸

· 真脸：本文与 GT 一样全黑， LiSiam 、 LRL 出现误报；假脸：本文的细线最接近 GT



论文 Figure 4： CDF2 上的 DSSIM 图估计结果

性能对比 · 同数据集（表 3、表 4）

Method	Test Set AUC (%) ↑				
	DF	F2F	FS	NT	FF++
LRL [2]	**100**	**100**	99.95	99.59	99.88
PCL+I2G [61]	**100**	99.57	**100**	99.58	99.79
LiSiam [47]	**100**	99.99	99.99	99.46	99.86
AUNet [1]	**100**	99.86	99.98	99.71	99.89
RAE [44]	99.60	99.10	99.20	97.60	98.90
DiffusionFF	**100**	**100**	99.90	**99.86**	**99.94**

· **表 3**： FF++ 上的检测 AUC； DF、 F2F、 FS、 NT 为四种伪造方法， FF++ 为整体

· 本文整体 99.94，第一；最难的 NT 上 99.86，也是第一

· 所有方法都在 98.9 以上，同数据集测试差距很小

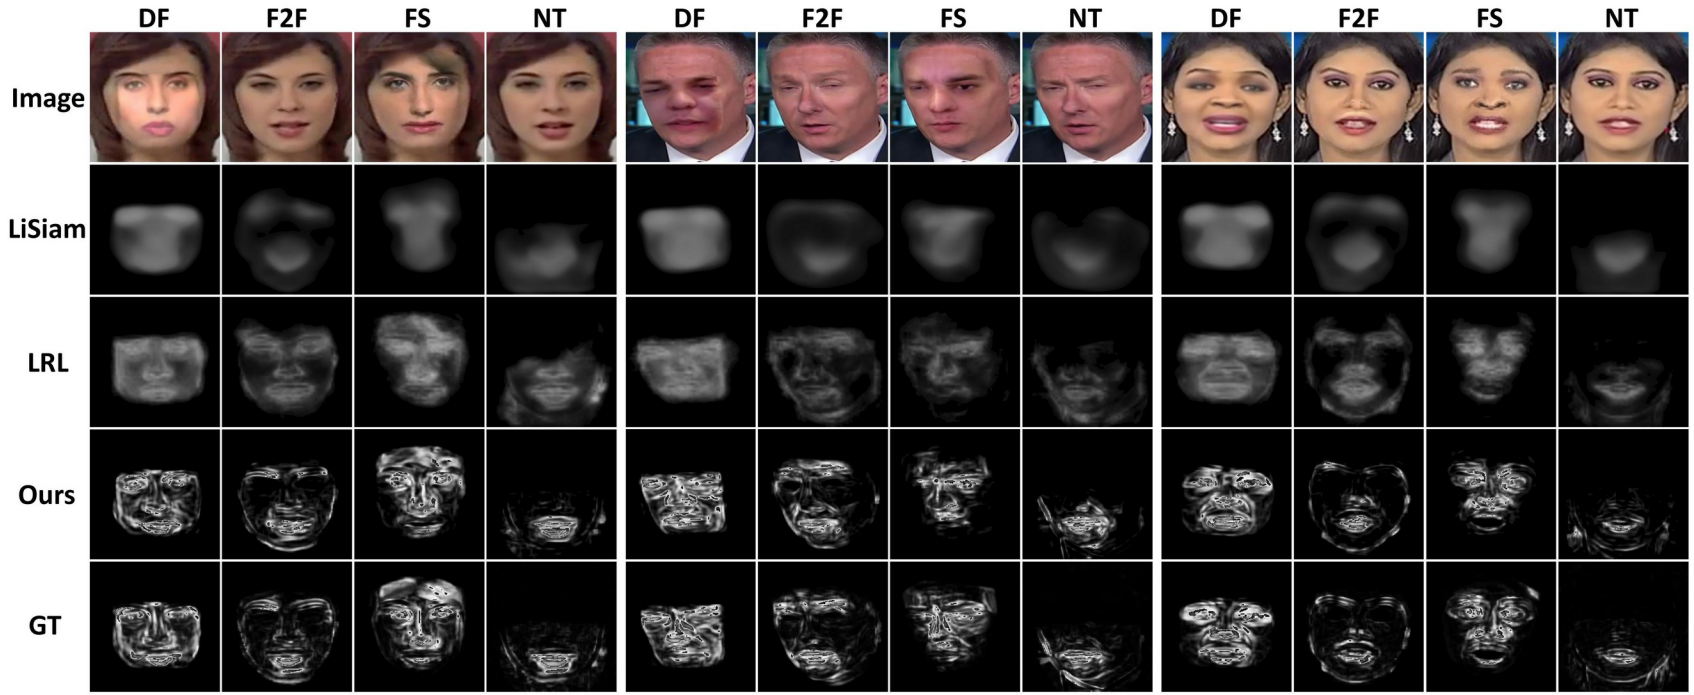
Method	Evaluation Metrics			
	PSNR↑	SSIM↑	LPIPS↓	FID↓
LiSiam [47]	20.753	0.408	0.426	292.149
LRL [2]	23.608	0.595	0.326	241.625
DiffusionFF	**26.376**	**0.718**	**0.198**	**43.093**

· **表 4**： FF++ 上 DSSIM 图的估计质量，四项指标全部最好

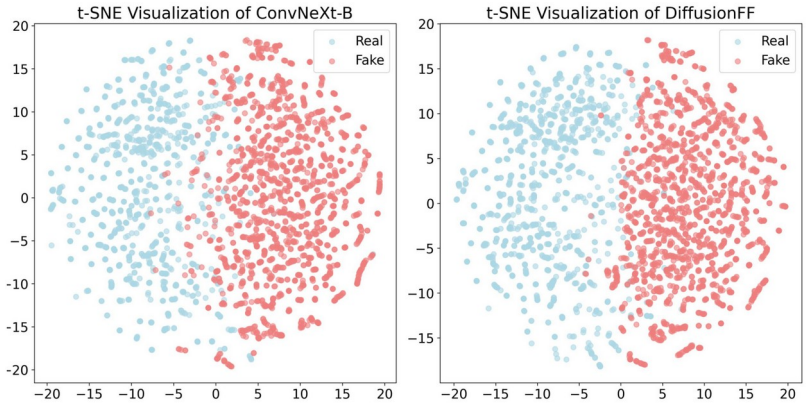
· 对比 LRL： PSNR 26.38 vs 23.61； SSIM 0.718 vs 0.595； LPIPS 0.198 vs 0.326

· FID 43.09， LRL 241.63、 LiSiam 292.15，提升最明显（FID 对模糊最敏感）

DiffusionFF 学到了什么



论文 Figure 5 （FF++）：三个人 × 四种伪造方法；行：输入、 LiSiam 、 LRL 、本文、 GT



论文 Figure 6： CDF2 上特征的 t-SNE （左： ConvNeXt-B ，右： DiffusionFF ）

· **定位**：本文的 DSSIM 图最接近 GT； NT 只改嘴部，本文也只在嘴附近画出痕迹

· **特征**：图 6 为 t-SNE （把高维特征压到二维平面），蓝 = 真脸，红 = 假脸；DiffusionFF （右）两类分得更开

· DSSIM 图让检测器更容易区分真假

消融实验 · 扩散模型的设计（表 5）

Method	Evaluation Metrics			
	PSNR↑	SSIM↑	LPIPS↓	FID↓
Direct Regression	24.341	0.584	0.252	172.213
Latent-Space Diffusion	24.228	0.680	0.217	56.384
Final-Stage Cond.	26.154	0.711	0.204	43.812
Decoder Cond.	26.253	0.716	0.202	46.329
The Proposed	**26.376**	**0.718**	**0.198**	**43.093**

· 用扩散代替直接回归， FID 从 172.2 降到 43.1，提升最大

· 潜空间扩散 FID 56.4，细节有损失；只用最后阶段 43.8、注入解码器 46.3，都略差

· 换掉任何一个设计，效果都会变差

· **Direct Regression**： 不用扩散，一次性输出 DSSIM 图

· **Latent-Space Diffusion**： 先压缩到潜空间再做扩散（类似 Stable Diffusion）

· **Final-Stage Cond.**： 只用检测器最后一个阶段的特征作条件

· **Decoder Cond.**： 把条件注入 U-Net 的解码器（右半边）

· **The Proposed**： 像素空间扩散 + 4 个尺度的条件 + 注入编码器（左半边）

消融实验 · 融合方式与两阶段训练（表 6 、补充材料表 2 ）

Method	Test Set AUC (%) ↑				Avg.
	CDF2	DFDC	DFDCP	FFIW	
Addition	95.79	84.68	91.56	88.38	90.10
Hadamard Product	96.46	84.53	91.37	88.40	90.19
Concatenation	96.66	85.00	91.87	**89.01**	90.64
Cross-Attention	97.19	84.91	92.26	88.46	90.71
Gating Mechanism	**97.24**	**85.05**	**92.56**	88.56	**90.85**

· **表 6**： 五种融合方式的跨数据集 AUC

· 平均：相加 90.10 、逐元素相乘 90.19 、拼接 90.64 、交叉注意力 90.71 、门控 90.85

· 门控平均最好； FFIW 上拼接 89.01 略高

Method	Test Set AUC (%) ↑			
	CDF2	DFDC	DFDCP	FFIW
Single-Stage	95.47	83.54	90.27	87.69
Two-Stage	**97.24**	**85.05**	**92.56**	**88.56**

补充材料 Table 2： 一阶段与两阶段训练

· **Single-Stage**： 画图与分类同时训练； **Two-Stage**： 本文的两阶段训练

· 两阶段在四个数据集上分别高 1.77 、 1.51 、 2.29 、 0.87

· 两个任务分开训练更好

泛化能力 · 换用不同的检测器（表 7）

Method	Params	Test Set AUC (%) ↑			
		CDF2	DFDC	DFDCP	FFIW
EfficientNet-B4	19M	93.18	72.42	86.15	84.83
+ DiffusionFF	32M	95.54	82.19	89.03	86.37
Swin-B	88M	95.59	82.81	89.74	85.38
+ DiffusionFF	101M	96.93	84.54	90.78	87.01
ConvNeXt-B	89M	96.08	84.26	90.20	87.67
+ DiffusionFF	102M	**97.24**	**85.05**	**92.56**	**88.56**

（下面每组四个数依次是 CDF2 、 DFDC 、 DFDCP 、 FFIW 上的 AUC 提升）

· **EfficientNet-B4**： CNN （ SBI 使用的网络）； +2.36 / +9.77 / +2.88 / +1.54

· **Swin-B**： Transformer （分阶段、多尺度）； +1.34 / +1.73 / +1.04 / +1.63

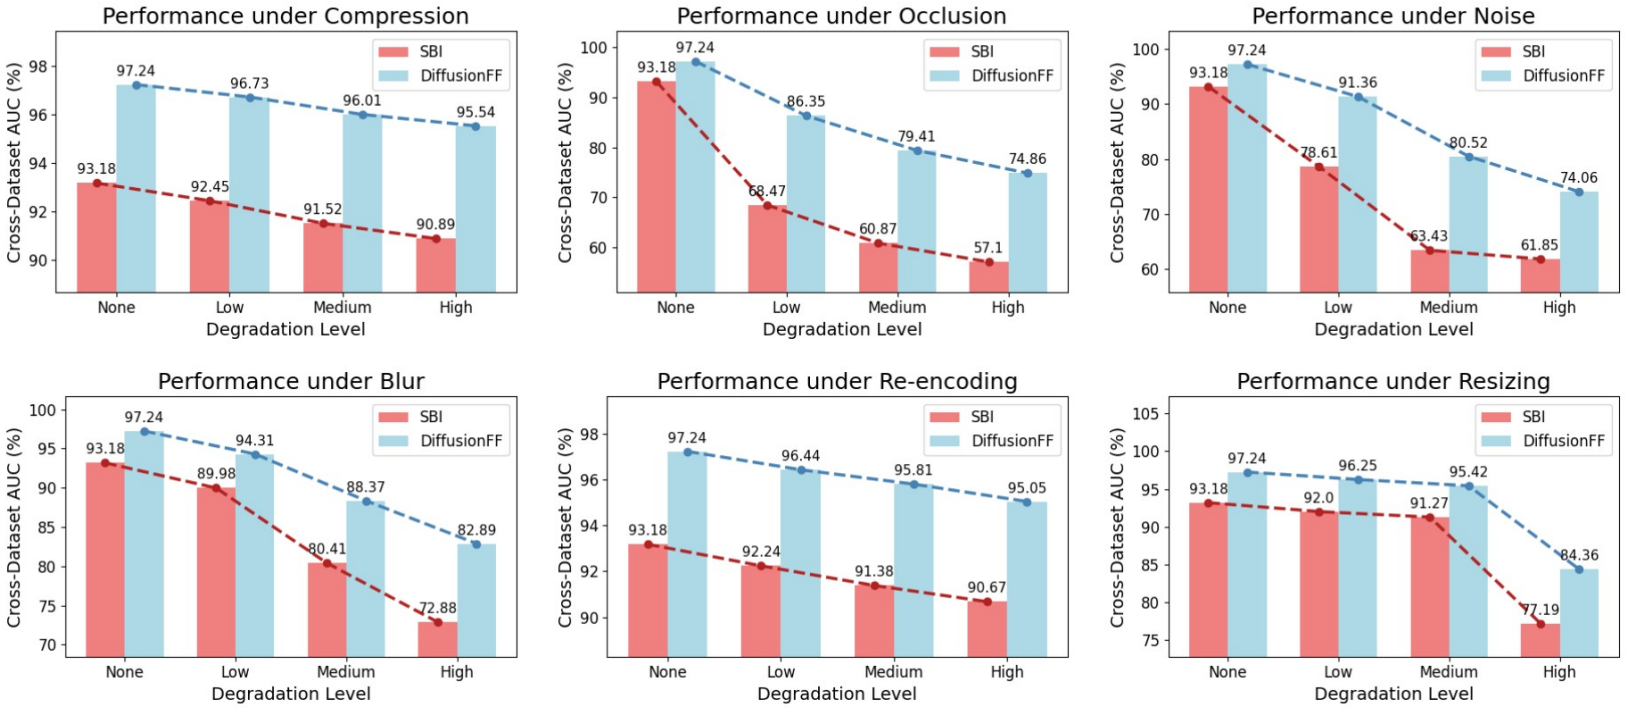
· **ConvNeXt-B**： 本文默认检测器； +1.16 / +0.79 / +2.36 / +0.89

· **Params**： 参数量（ M = 百万），都增加约 13M

· ViT 只有单一尺度的特征，无法接入，未测试

· 可作为即插即用模块：提升不同检测器，并提供定位图

泛化能力 · 鲁棒性（图 7）



· 在 CDF2 上测试；红 = SBI，蓝 = DiffusionFF；横轴为干扰强度（None / Low / Medium / High）

· 六种干扰：JPEG 压缩、随机遮挡、高斯噪声、高斯模糊、反复重新编码、缩小再放大

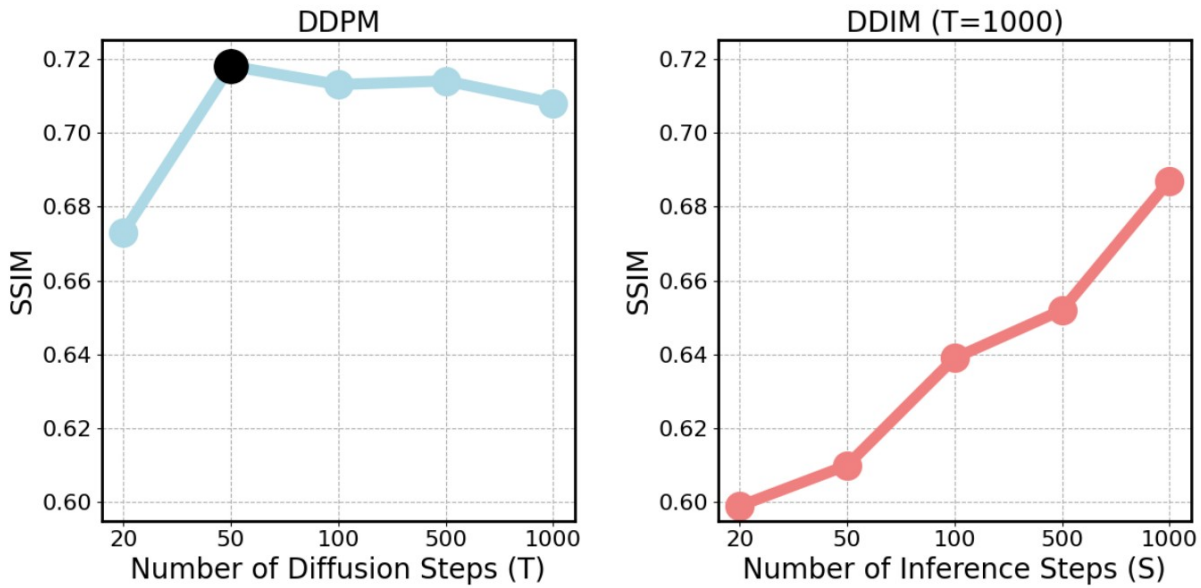
· 所有干扰、所有强度下 DiffusionFF 都更高

· 差距最大：低强度遮挡 86.35 vs 68.47；中等噪声 80.52 vs 63.43

· 强度设置：压缩质量 95 / 85 / 75；遮挡 2% / 5% / 10%；噪声标准差 0.01 / 0.05 / 0.1；模糊 5/1、7/2、9/3；重新编码 2 / 3 / 4 次；缩放 0.75 / 0.5 / 0.25

· 注意：SBI 使用 EfficientNet-B4，本文使用更强的 ConvNeXt-B

超参数敏感性分析

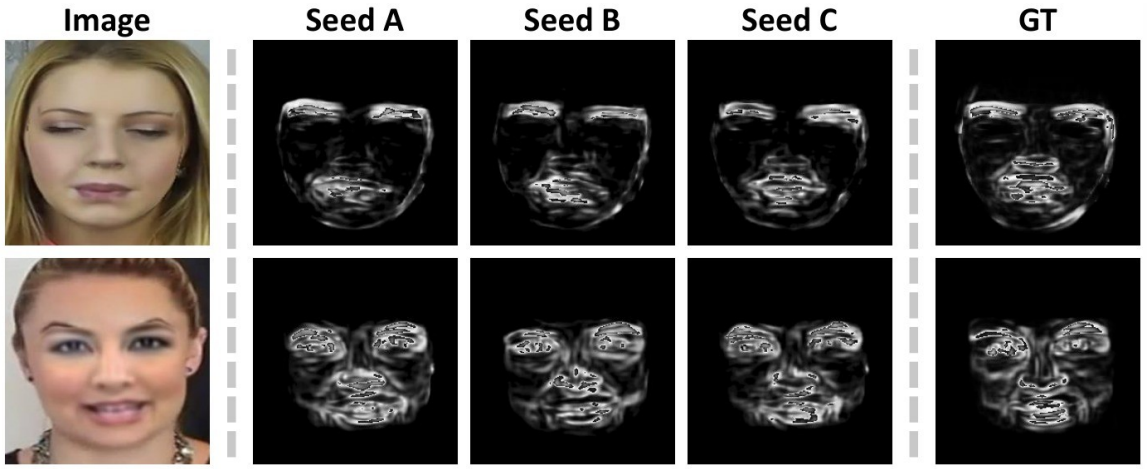


补充材料 Figure 2： 扩散步数的影响

· 左： DDPM 不同总步数 T： 20 → 0.673， 50 → 0.718 （最高，黑点）， 100 ～ 1000 → 约 0.71

· 右： DDIM （用 T = 1000 训练，推理只走 S 步）： S 越多越好，最高 0.687，仍不如 DDPM

· 最终选择 DDPM， T = 50



补充材料 Figure 3： 不同随机种子的结果

· 扩散从随机噪声出发，随机种子决定起点的噪声图

· 三个种子 A 、 B 、 C 画出的痕迹位置和形状基本一致，结果稳定

总结

贡献

1、编码器 - 解码器结构：预训练伪造检测器作伪影编码器，扩散模型作伪影解码器，逐步生成精细的 DSSIM 图

2、门控融合：把 DSSIM 图与检测器高层特征融合，提升检测

3、跨数据集检测 4 项第一，定位质量明显优于已有 DSSIM 方法，可即插即用

局限

· 推理慢：完整流程 0.34 秒 / 帧（1990 GFLOPs），检测器单独 0.01 秒（15 GFLOPs）

· 训练需要逐像素对齐的真假图对（可用 SBI 合成）；不适用于完全由 AI 生成的图像

思考

· 扩散模型的数学来自 DDPM，创新在于用它生成 DSSIM 图并与检测器组合

· 相对自身检测器， AUC 提升 0.79 ～ 2.36； DFDC、 FFIW 上只领先第二名 0.27、 0.03

谢谢！请老师和同学们批评指正